



Tecnológico de Monterrey

Maestría en Inteligencia Artificial Aplicada

Análisis de Grafos y Extrapolación de Conocimiento
para identificar Relaciones No Explícitas de
información

Cobertura del espacio de inductividad dentro del marco de
Knowledge Extrapolation

Profesor Dr. Gerardo Jesús Camacho González

Profesor Dr. Eusebio Vargas Estrada

Equipo 32

José Adan Vega Pérez	A01796093
Silvia Xochitl Ibañez Vara	A01795200
Diego Andrés Bernal Díaz	A01795975

Introducción	3
Justificación de Selección de Modelos.....	4
Relevancia para escenarios OOKB	5
Metodología de Evaluación	5
Métricas utilizadas	6
Evaluación por escenario	6
Gap de desempeño	6
Progresión Experimental de Enfoques Inductivos en Grafos de Conocimiento	6
0. OOKB	7
1. Clasificador simple de tripletas	8
2. R-GCN - Relational Graph Convolutional Network	9
3. RGAT - Relational Graph Attention Network	12
4. InGRAM.....	14
5. IKGE.....	16
Referencias	18

Introducción

Los métodos de Knowledge Graph Completion (KGC) han sido históricamente evaluados bajo un supuesto transductivo: el conjunto de entidades y relaciones permanece fijo entre entrenamiento e inferencia. Sin embargo, este supuesto limita la aplicabilidad de los modelos en entornos dinámicos, donde los grafos evolucionan y pueden incorporar elementos no observados previamente.

En este contexto, el problema puede enmarcarse dentro del paradigma más amplio de Knowledge Extrapolation (KE), entendido como la capacidad de un modelo para generalizar más allá de los elementos y patrones vistos durante el entrenamiento (Chen et al., 2023). Desde esta perspectiva, los escenarios *Out-of-Knowledge-Base* (OOKB) constituyen un caso particular de extrapolación estructural, en el que emergen nuevas entidades, nuevas relaciones o combinaciones no observadas.

Bajo este marco, la presente entrega no se organiza como una comparación directa de desempeño entre arquitecturas, sino como un análisis de la cobertura del espacio de inductividad. Específicamente, se examina cómo distintos modelos incorporan mecanismos que les permiten generalizar ante distintos tipos de novedad estructural.

Para ello, se seleccionaron arquitecturas representativas que cubren niveles crecientes de generalización relacional:

- Sin inductividad: modelos transductivos como RCGN y RGAT, que asumen un universo fijo de entidades y relaciones.
- Inductividad parcial: modelos como IKGE, capaces de generar representaciones para entidades no vistas, manteniendo fijo el conjunto de relaciones
- Inductividad completa: modelos como INGRAM, diseñados para generalizar tanto a nuevas entidades como relaciones.

Este encuadre permite analizar el impacto del nivel de inductividad sobre la capacidad de generalización en escenarios OOKB, desplazando el foco desde el rendimiento absoluto hacia la comprensión de los supuestos estructurales que coincidan cada modelo. El objetivo no es establecer un ranking, sino identificar qué grado de inductividad resulta necesario para enfrentar grafos dinámicos.

Justificación de Selección de Modelos

La selección de los modelos RGCN, RGAT, IKGE e INGRAM responden a un criterio estructural en la cobertura progresiva del espacio de inductividad:

- RGCN: representa el paradigma transductivo relacional estándar, basado en convolución sobre grafos con un universo fijo de entidades y relaciones (Schlichtkrull et al., 2018).
- RGAT introduce mecanismos de atención en grafos relacionales, permitiendo estudiar si una agregación adaptativa mejora la capacidad de generalización sin cambiar el supuesto transductivo (Busbridge et al., 2019).
- IKGE incorpora inductividad a nivel de entidades, permitiendo generar embeddings para nodos no observados en entrenamiento (Hamaguchi et al., 2017).
- INGRAM extiende la inductividad al nivel relacional, permitiendo generalizar tanto a nuevas entidades como a nuevas relacionales (Lee et al., 2023).

Esta progresión permite analizar cómo varía el desempeño a medida que se modifican los supuestos estructurales del modelo. La inclusión conjunta de R-GCN y RGAT permite estudiar el impacto del mecanismo de agregación manteniendo constante el paradigma de aprendizaje, mientras que IKGE e INGRAM permiten evaluar el efecto de introducir distintos grados de inductividad.

Los cuatro modelos comparten una base conceptual común, el modelado relacional mediante propagación de mensajes o generación estructural de embeddings, lo que garantiza comparabilidad dentro de un mismo marco experimental.

Relevancia para escenarios OOKB

El enfoque OOKB implica enfrentar la aparición de entidades o relaciones no observadas durante el entrenamiento. Dado que la mayoría de los modelos de KGC han sido evaluados bajo condiciones transductivas, esta selección permite mapear de manera explícita:

- La degradación bajo ausencia inductiva (R-GCN, RGAT).
- La mejora parcial al incorporar inductividad en entidades (IKGE).
- La capacidad de generalización estructural completa (INGRAM).

En conjunto, este análisis permite identificar qué nivel de inductividad es necesario para abordar grafos dinámicos de manera robusta.

Metodología de Evaluación

La evaluación se centra en medir el desempeño de los modelos en tareas de predicción de enlaces bajo distintos escenarios experimentales previamente definidos. Para garantizar comparabilidad con la literatura en KGC se emplean métricas de ranking en su versión *filtered*.

Métricas utilizadas

- Mean Reciprocal Rank (MRR): métrica principal del análisis, que refleja la posición promedio del enlace correcto en el ranking generado por el modelo.
- Hits@1: proporción de predicciones correctas en primera posición.
- Hits@10: proporción de predicciones correctas dentro de las diez primeras posiciones.

La configuración *filtered* excluye del conjunto de candidatos aquellas tripletas válidas adicionales presentes en los datos, evitando penalizaciones indebidas.

Evaluación por escenario

Las métricas se reportan de manera separada para cada escenario experimental considerado. Esto permite analizar el comportamiento de los modelos según el tipo de condición estructural evaluada, evitando que un promedio global oculte diferencias relevantes.

Gap de desempeño

Como medida complementaria, se calcula la diferencia entre el desempeño en el escenario base y el observado en los escenarios inductivos. Este indicador permite cuantificar la variación en rendimiento ante cambios en las condiciones del grafo.

$$\Delta = MRR_{transductivo} - MRR_{OoKB}$$

Progresión Experimental de Enfoques Inductivos en Grafos de Conocimiento

El diseño experimental no solo siguió una progresión conceptual, sino también una transición en la naturaleza de la representación aprendida.

- R-GCN y RGAT dependen de embeddings asociados explícitamente a las entidades observadas durante el entrenamiento, lo que restringe su aplicabilidad a un universo cerrado.
- IKGE introduce un mecanismo generativo que permite construir representaciones para nodos no observados a partir de su vecindad estructural.
- INGRAM amplía este enfoque al modelar explícitamente las relaciones como estructuras generativas, reduciendo la dependencia de un conjunto fijo de operadores relacionales.

Esta secuencia no solo incrementa el nivel de inductividad, sino que transforma la forma en que el modelo codifica y utiliza la información estructural del grafo.

0. OOKB

El enfoque Out-of-Knowledge-Base (OOKB), propuesto originalmente por Hamaguchi et al., aborda el problema inductivo en grafos de conocimiento: cómo generar representaciones para entidades que no estuvieron presentes durante el entrenamiento. A diferencia del escenario transductivo clásico, donde todas las entidades aparecen al menos una vez en train, OOKB asume que en los conjuntos de validación y prueba pueden existir entidades nuevas cuya representación debe inferirse únicamente a partir de su conectividad en un grafo auxiliar. La idea central consiste en no asignar embeddings aprendidos directamente a estas entidades OOKB, sino construirlos dinámicamente mediante agregación estructural de sus vecinos conocidos, típicamente a través de un promedio o combinación ponderada de embeddings ya entrenados.

El aspecto crítico de la propuesta radica en su dependencia explícita de la estructura local del grafo: la calidad de la representación de una entidad OOKB está directamente limitada por la cantidad y calidad de sus conexiones disponibles. En contextos donde la conectividad es escasa, la señal estructural puede resultar insuficiente para construir representaciones discriminativas robustas. No obstante, OOKB establece un marco conceptual clave: la representación de entidades puede generarse inductivamente a partir de estructura, sin necesidad de reentrenar el modelo completo. En este trabajo, OOKB funciona como punto de partida histórico y referencia conceptual para contrastar

soluciones más simples —como clasificadores directos de tripletas— y extensiones estructurales progresivamente más sofisticadas, hasta llegar a propuestas inductivas más generales como InGRAM.

1. Clasificador simple de tripletas

Con el propósito de establecer una referencia experimental clara para el problema de clasificación binaria de tripletas, se implementó un modelo base deliberadamente simple, compuesto por embeddings independientes de entidades y relaciones, seguidos de un clasificador multicapa (MLP) entrenado mediante pérdida de entropía cruzada binaria. Aunque el problema se encuentra históricamente relacionado con enfoques como OOKB (Out-of-Knowledge-Base), en esta fase no se buscó reproducir dicho diseño ni incorporar mecanismos explícitos de propagación estructural en el grafo. La intención fue, en cambio, construir una línea base que represente la forma más directa y menos estructural de abordar la clasificación de tripletas, utilizando únicamente información de co-ocurrencia aprendida a partir del grafo formado por la unión de los conjuntos train y aux.

Bajo esta configuración, dimensión reducida del embedding, regularización L2 y criterio de early stopping basado en validación, el modelo alcanzó un desempeño promedio de $61.77\% \pm 0.38\%$ en el conjunto de prueba (promedio sobre tres semillas aleatorias). Este resultado constituye un punto de referencia cuantitativo importante: para este dataset específico, cualquier modelo con mayor complejidad arquitectónica, como aquellos basados en R-GCN u otros mecanismos de agregación estructural, deberá superar aproximadamente el 61.8% de exactitud para justificar su incremento en complejidad y costo computacional.




Figure 1. Esquema Clasificador de Tripletas

..	
datasets	Windows friendly files + aux
util	Original OOKB from paper
best_model.pt	mejor clasificador de tripletas
example.sh	Update example.sh
main.py	original model and different approaches
model.py	original model and different approaches
predictions_head-1000.json	Model Candidate
transe_main.py	+simple triple classifier
transe_model.py	+TransE
triple_classifier_main.py	mejor clasificador de tripletas
triple_classifier_model.py	+simple triple classifier

Figure 2. Ubicacion de archivo .py de Clasificación de Tripletas

2. R-GCN - Relational Graph Convolutional Network

Como siguiente paso después del clasificador simple basado únicamente en las tripletas (h,r,t), se implementó un modelo Relational Graph Convolutional Network (RGCN) de una sola capa, aprovechando que las tripletas de entrenamiento y auxiliares permiten construir un grafo relacional completo. En este enfoque, las representaciones de las entidades no se aprenden de manera independiente, sino que se actualizan mediante agregación estructural de sus vecinos directos en el grafo, utilizando matrices de transformación específicas por relación. Posteriormente, estas representaciones enriquecidas se combinan con el embedding de la relación en un decodificador MLP para realizar la clasificación binaria de tripletas. Conceptualmente, este modelo incorpora información estructural explícita del grafo, a diferencia del clasificador simple que opera únicamente sobre la factorización directa de las tripletas.

En términos de resultados, el modelo RGCN de una capa alcanzó un desempeño estable alrededor de 0.51–0.52 de accuracy en test, ligeramente superior pero muy cercano al clasificador simple. Esto sugiere que, para el conjunto head-1000, la información estructural de primer orden (vecinos directos) no aporta una mejora significativa respecto al modelo base. En otras palabras, la señal discriminativa presente en la estructura inmediata del grafo parece ser limitada o ya estar implícitamente capturada por el modelo de factorización inicial. Este hallazgo indica que, bajo esta configuración, una sola capa de propagación relacional no es suficiente para explotar patrones estructurales más complejos, lo que abre la posibilidad de explorar arquitecturas más profundas o mecanismos de atención para capturar dependencias multi-salto.




Figure 4. Esquema R-GCN

Name	Last commit message
..	
datasets	Windows friendly files + aux
util	Original OOKB from paper
example.sh	Update example.sh
main.py	original model and different approaches
model.py	original model and different approaches
predictions_head-1000.json	Model Candidate
rgcn_main.py	R-GCN 1 layer
rgcn_model.py	R-GCN 1 layer
triple_classifier_main.py	mejor clasificador de tripletas

Figure 3. Ubicación archivo .py de R-GCN

3. RGAT - Relational Graph Attention Network

En este experimento abordamos el escenario **Out-of-Knowledge-Base (OOKB)** bajo la partición propuesta originalmente, donde las tripletas de *dev* y *test* contienen entidades con **presencia limitada dentro del grafo de entrenamiento**. Este planteamiento implica un reto inductivo: el modelo debe inferir la validez de nuevas tripletas a partir de información estructural escasa, apoyándose principalmente en la conectividad disponible en el grafo auxiliar. Para ello se implementó un modelo basado en **Relational Graph Attention (RGAT)**

con dos capas de propagación, lo que permite incorporar información de **vecinos y vecinos de vecinos** (propagación de segundo orden). De esta manera, cada entidad OOKB puede enriquecer su representación no solo con sus conexiones directas, sino también con contexto estructural de mayor alcance.

Los resultados muestran una exactitud máxima cercana al **69%**, con variación mínima entre distintas semillas aleatorias, lo que indica estabilidad del modelo. Considerando que las entidades evaluadas poseen baja frecuencia y conectividad reducida dentro del grafo, este desempeño puede interpretarse como un límite práctico impuesto por la propia distribución OOKB: la escasez estructural restringe la cantidad de información explotable. En este sentido, el desempeño alcanzado sugiere que la propagación a dos saltos es suficiente para capturar la mayor parte de la señal disponible en el grafo bajo esta configuración, y que mejoras adicionales probablemente requerirían modificaciones en la distribución de datos o en el tipo de información incorporada, más que únicamente ajustes arquitectónicos menores.




Figure 5. Esquema RGAT

Name	Last commit message
..	
datasets	Windows friendly files + aux
util	Original OOKB from paper
example.sh	Update example.sh
main.py	original model and different approaches
model.py	original model and different approaches
predictions_head-1000.json	Model Candidate
rgat_main.py	+seed
rgat_model.py	RGAT 71% acc
rgcn_main.py	R-GCN 1 layer
rgcn_model.py	R-GCN 1 layer
triple_classifier_main.py	mejor clasificador de tripletas
triple_classifier_model.py	+simple triple classifier

Figure 6. Ubicación de archivo .py de RGAT

4. InGRAM

INGRAM constituye un enfoque inductivo más general que los modelos inspirados en OOKB, al proponer un mecanismo jerárquico de representación estructural para relaciones y entidades. A diferencia de los modelos tradicionales donde los embeddings son parámetros directamente aprendidos y asociados a identidades específicas, INGRAM aprende operadores estructurales que transforman la conectividad del grafo en representaciones vectoriales. Primero construye un *relation graph*, donde cada relación es un nodo y las aristas reflejan afinidad estructural basada en entidades compartidas y normalizadas por grado. Posteriormente, realiza una agregación de relaciones entre sí para obtener representaciones ocultas de relaciones, las cuales son utilizadas en una segunda etapa de agregación para construir representaciones de entidades a partir de pares (entidad vecina, relación). El modelo es entrenado mediante una función de ranking tipo margin-based loss, optimizando la plausibilidad relativa de tripletas verdaderas frente a corruptas.

Desde la perspectiva comparativa con enfoques basados en OOKB, la principal diferencia radica en el nivel de abstracción del aprendizaje. Mientras que OOKB y extensiones con R-GCN se enfocan en generar embeddings para entidades nuevas a partir de sus vecinos,

manteniendo relaciones como parámetros esencialmente transductivos, INGRAM introduce un nivel meta-estructural donde las relaciones mismas son inducidas a partir de su posición en el grafo. Esto permite generalizar no solo a entidades nuevas, sino también a relaciones no observadas durante el entrenamiento, siempre que exista estructura suficiente para determinar afinidades. En este sentido, INGRAM no memoriza embeddings específicos, sino que aprende la forma estructural del grafo, proporcionando un marco inductivo más amplio que sirve como referencia sólida frente a los modelos que toman OOKB únicamente como punto de partida histórico.

En cuanto al esquema de evaluación, existe una diferencia metodológica relevante entre los enfoques tipo OOKB y la propuesta de INGRAM. Los modelos inspirados en OOKB, así como los clasificadores binarios derivados de esta línea, formulan el problema como una tarea de **clasificación de tripletas**, donde se generan ejemplos negativos mediante corrupción y el modelo aprende a distinguir entre tripletas verdaderas y falsas. En contraste, INGRAM aborda el problema como **link prediction por ranking**: dada una triplete incompleta, el modelo evalúa todas las posibles entidades candidatas y ordena los puntajes según su plausibilidad estructural. La entidad correcta se evalúa en función de su posición en este ranking, utilizando métricas como MRR o Hits@K. En este contexto, el ranking no proviene de una decisión binaria directa, sino de la geometría inducida por los parámetros aprendidos —operadores estructurales de agregación y transformación— que encapsulan la organización relacional del grafo. De este modo, la evaluación en INGRAM refleja qué tan coherentemente el modelo ha internalizado la estructura global del grafo, más que su capacidad de discriminar instancias positivas y negativas de forma aislada.




Figure 7. Esquema InGRAM

Name	Last commit message	Last commit
..		
Dockerfile	+GPU +results	18 min
README.md	Readme structure	7 min
README.md		
🔗 Definición de imagen y contenedor para replicar InGRAM: https://github.com/bdi-lab/InGram/ https://arxiv.org/pdf/2305.19987 CMD build: <code>docker build --no-cache -t ingram .</code> or <code>docker build -t ingram .</code>		

5. IKGE

En el espectro de la generalización relacional, el modelo IKGE (*Inductive Knowledge Graph Embedding*) representa un avance significativo al abordar el problema OOKB desde una perspectiva híbrida. A diferencia de los enfoques puramente basados en la topología del grafo (como R-GCN y RGAT), IKGE no depende exclusivamente de que las entidades tengan conexiones densas preexistentes para inferir sus representaciones. En su lugar, rompe con el supuesto transductivo utilizando información auxiliar compartida a nivel de palabra (*side information*), tal como descripciones textuales, nombres y restricciones de tipo. Esto le permite generar dinámicamente representaciones vectoriales para entidades no vistas durante el entrenamiento, extrayendo la semántica de sus descripciones y mitigando la falta de señal estructural inicial.

Arquitectónicamente, el modelo opera en dos fases fundamentales. La primera es la **Extracción de Información de Características (Fact Feature Extraction)**, donde se procesan las descripciones textuales utilizando redes neuronales convolucionales con un mecanismo de atención de doble vía. Esta atención cruzada pondera las palabras más relevantes de la descripción de una entidad en función del nombre de la relación y del contexto de la entidad vecina. Adicionalmente, aplica un filtrado basado en restricciones de tipo (*type matching*) para asegurar la viabilidad semántica de la tripleta. El resultado es un

embedding inicial del hecho que captura las propiedades intrínsecas de los nodos, incluso si son entidades OOKB puras sin conexiones previas.

La segunda fase consiste en la **Agregación Atencional de Características (Attentive Feature Aggregation)**, mediante la cual el modelo reintroduce e internaliza la geometría del grafo. A partir de las representaciones iniciales basadas en texto, IKGE acumula jerárquicamente las características de los hechos vecinos a múltiples saltos (*multi-hop*). Empleando un agregador con atención, el modelo aprende a dar mayor peso a las vecindades más relevantes y fusiona este contexto global estructural con el vector inicial de la tripleta objetivo. Finalmente, esta representación enriquecida y consciente del contexto es evaluada por un clasificador multicapa (MLP) que determina la plausibilidad final de la tripleta (verdadera o falsa), combinando armónicamente la generalización semántica del texto con la topología relacional.




Figure 8. Esquema IKGE

Referencias

- Bordes, A., Usunier, N., Garcia-Durán, A., Weston, J., & Yakhnenko, O. (2013). *Translating embeddings for modeling multi-relational data*. In **Advances in Neural Information Processing Systems** (Vol. 26). <https://papers.nips.cc/paper/2013/hash/1cecc7a77928ca8133fa24680a88d2f9-Abstract.html>
- Chen, M., Zhang, W., Geng, Y., Xu, Z., Pan, J. Z., & Chen, H. (2023). *Generalizing to unseen elements: A survey on knowledge extrapolation for knowledge graphs*. arXiv. <https://arxiv.org/abs/2302.01859>
- Hamilton, W. L., Ying, R., & Leskovec, J. (2017). *Inductive representation learning on large graphs*. In **Advances in Neural Information Processing Systems** (Vol. 30). <https://arxiv.org/abs/1706.02216>
- Hamaguchi, T., Oiwa, H., Shimbo, M., & Matsumoto, Y. (2017). *Knowledge transfer for out-of-knowledge-base entities: A graph neural network approach*. arXiv. <https://arxiv.org/abs/1706.05674>
- Lee, J., Chung, C., & Whang, J. J. (2020). *INGRAM: Inductive knowledge graph embedding via relation graphs*. In **Proceedings of the AAAI Conference on Artificial Intelligence**, 34(03), 4054–4061. <https://doi.org/10.1609/aaai.v34i03.5865>
- Nickel, M., Murphy, K., Tresp, V., & Gabrilovich, E. (2016). *A review of relational machine learning for knowledge graphs*. **Proceedings of the IEEE**, 104(1), 11–33. <https://doi.org/10.1109/JPROC.2015.2483592>
- Schlichtkrull, M., Kipf, T. N., Bloem, P., van den Berg, R., Titov, I., & Welling, M. (2018). *Modeling relational data with graph convolutional networks*. In **The Semantic Web – ESWC 2018** (Lecture Notes in Computer Science, Vol. 10843, pp. 593–607). Springer. https://doi.org/10.1007/978-3-319-93417-4_38
- Teru, K. K., Denis, E., & Hamilton, W. L. (2020). Inductive relation prediction by subgraph reasoning. In *Proceedings of the 37th International Conference on Machine Learning* (pp. 9448–9457). PMLR. <https://arxiv.org/abs/1911.06962>