



Tecnológico de Monterrey

Maestría en Inteligencia Artificial Aplicada

Análisis de Grafos y Extrapolación de Conocimiento
para identificar Relaciones No Explícitas de
información

Investigación

Profesor Dr. Gerardo Jesús Camacho González

Profesor Dr. Eusebio Vargas Estrada

Equipo 32

José Adan Vega Pérez	A01796093
Silvia Xochitl Ibañez Vara	A01795200
Diego Andrés Bernal Díaz	A01795975

<i>Introducción</i>	<i>2</i>
<i>Contexto metodológico de InGram.....</i>	<i>3</i>
<i>Funcionamiento de InGram y el papel de L.....</i>	<i>3</i>
<i>Hipótesis: mayor profundidad como mecanismo de mejor aprendizaje</i>	<i>3</i>
<i>Análisis general de resultados</i>	<i>3</i>
<i>Presentación general de resultados.....</i>	<i>3</i>
<i>Naturaleza cualitativa de los datasets.....</i>	<i>3</i>
<i>Comentario analítico preliminar</i>	<i>3</i>
<i>Análisis por caso</i>	<i>3</i>
<i>Conclusión</i>	<i>3</i>
<i>Propuesta para la selección adaptativa de la profundidad estructural</i>	<i>3</i>
<i>Referencias</i>	<i>3</i>

Introducción

Este proyecto aborda el problema de la extrapolación de conocimiento en grafos dinámicos, particularmente en escenarios donde emergen entidades no observadas durante el entrenamiento (Out-Of-Knowledge-Base, OOKB). A diferencia de los enfoques tradicionales de *Knowledge Graph Embedding*, que asumen un conjunto cerrado de entidades (Bordes et al., 2013; Nickel et al., 2016), se busca analizar y caracterizar modelos inductivos capaces de generalizar patrones estructurales hacia nodos nuevos sin requerir reentrenamiento completo. En esta etapa, el estudio se centra en el análisis de sensibilidad arquitectónica del modelo InGram (Lee et al., 2023), evaluando el impacto de la profundidad de propagación en entidades y relaciones sobre métricas como MRR y Hits@K. Más allá de identificar la configuración con mayor desempeño numérico, el objetivo es comprender bajo qué condiciones estructurales el modelo mejora o se degrada. Este enfoque permite evaluar de manera crítica si incrementos en complejidad arquitectónica se traducen en mejoras sustantivas de generalización inductiva.

Contexto metodológico de InGram

InGram parte de la idea de que la generalización inductiva en grafos de conocimiento no debe depender de embeddings asociados permanentemente a identificadores específicos de entidades o relaciones, sino de la estructura que las conecta. Para ello, introduce primero el concepto de un grafo de relaciones, donde cada nodo representa una relación del grafo original y las aristas codifican afinidades estructurales entre relaciones. Estas afinidades se calculan a partir de patrones de co-ocurrencia y conectividad observados en las tripletas del grafo, permitiendo construir una estructura relacional de segundo orden que captura cómo interactúan las relaciones entre sí.

Una vez definido este grafo relacional, el modelo realiza propagación de mensajes sobre él para obtener representaciones estructurales de relaciones (hr). Estas representaciones no dependen de descripciones textuales ni de parámetros fijos por identidad, sino de la posición estructural de cada relación dentro del grafo relacional.

Posteriormente, estas representaciones de relaciones se utilizan para construir las representaciones de entidades (he). En este proceso, cada entidad agrega información proveniente de sus vecinos en el grafo original, considerando tanto las entidades conectadas como las relaciones que median dichas conexiones. De esta forma, las representaciones de entidades se construyen condicionalmente a la estructura local compuesta por entidades y relaciones ya procesadas.

El modelo se entrena utilizando las representaciones estructurales h_r y h_e para puntuar tripletas y optimizar una función de pérdida basada en predicción de enlaces. Sin embargo, a diferencia de modelos tradicionales de embeddings, InGram no aprende vectores permanentes asociados a identificadores específicos. En cada episodio inductivo, las representaciones se reinician y se reconstruyen únicamente a partir de la estructura observable del grafo disponible en ese momento.

En consecuencia, lo que el modelo aprende no son entidades o relaciones particulares, sino el mecanismo estructural que permite derivar representaciones a partir de la conectividad del grafo. Esta propiedad es la que habilita la generalización inductiva: ante nuevas entidades o nuevas particiones del grafo, el modelo no necesita embeddings pre-entrenados, sino que reconstruye las representaciones desde cero utilizando la estructura de conocimiento presente.

Funcionamiento de InGram y el papel de L

InGram es un modelo inductivo de Knowledge Graph Embedding que aprende representaciones para entidades y relaciones a partir de la estructura local del grafo. Su arquitectura se compone de dos módulos principales:

1. Uno que opera sobre el grafo de entidades.
2. Sobre el grafo de relaciones.

En ambos casos, el modelo realiza propagación de mensajes a través de capas sucesivas, donde el hiperparámetro L determina la profundidad de agregación estructural. Es decir, L controla cuántos niveles de vecinos son considerados al construir la representación oculta de cada nodo (entidad o relación). Cuando $L=1$, la representación depende únicamente de vecinos inmediatos; cuando $L=2$, incorpora vecinos de vecinos, y así sucesivamente. Por tanto, L define explícitamente el alcance estructural del contexto que el modelo utiliza para inferir nuevas tripletas.

Hipótesis: mayor profundidad como mecanismo de mejor aprendizaje

Desde una perspectiva teórica, incrementar la profundidad L podría permitir al modelo capturar patrones estructurales más complejos y dependencias de mayor alcance dentro del grafo. En principio, una mayor propagación de información debería enriquecer las representaciones latentes al incorporar señales provenientes de regiones más amplias del

grafo. Esto podría ser particularmente útil en escenarios inductivos, donde las entidades nuevas requieren apoyarse en la estructura circundante para generalizar adecuadamente. Bajo esta hipótesis, esperaríamos observar mejoras progresivas en métricas como MRR y Hits@K conforme aumenta L , al menos hasta cierto punto

Análisis general de resultados

Los resultados obtenidos muestran que la profundidad óptima no es uniforme entre entidades y relaciones. En el caso de las entidades, se observa un patrón relativamente estable en los tres datasets: $L_e = 2$ produce los mejores resultados o se mantiene muy cercano al mejor desempeño en términos de MRR y Hits@K. Esto sugiere que incorporar información de vecinos de primer y segundo orden proporciona un equilibrio adecuado entre contexto estructural y preservación de identidad local. Profundidades mayores tienden a degradar el rendimiento, lo que es compatible con fenómenos de sobre-suavizado (over-smoothing) o introducción de ruido estructural.

En contraste, para las relaciones no se observa una profundidad óptima universal. Cada dataset presenta un valor distinto de L_r que maximiza el desempeño: en NL-25 el mejor resultado se obtiene con $L_r = 1$, en WK-25 con $L_r = 3$, y en FB-25 con $L_r = 2$. Esta variabilidad indica que la estructura del grafo de relaciones y la forma en que las afinidades inter-relacionales se organizan dependen fuertemente de las características propias de cada dataset. En consecuencia, la profundidad óptima para relaciones parece ser dependiente del dominio y no un hiperparámetro con comportamiento estable entre escenarios.

En conjunto, estos hallazgos sugieren que mientras la agregación estructural en entidades presenta un punto de operación relativamente robusto ($L_e = 2$), la propagación en el grafo de relaciones requiere una calibración específica por dataset, lo cual refuerza la idea de que ambos sub-módulos de InGram responden de manera distinta a la expansión del contexto estructural.

Presentación general de resultados

En esta sección se presentan los resultados obtenidos al evaluar distintas configuraciones de profundidad estructural en InGram, variando de manera independiente

el número de capas en el módulo de entidades (Le) y en el módulo de relaciones (Lr), manteniendo el valor default complementario en cada experimento. Las evaluaciones se realizaron sobre tres datasets bajo el esquema NL-25, WK-25 y FB-25, utilizando como métricas principales Mean Reciprocal Rank (MRR), Hits@10 y Hits@1.

El objetivo de esta exploración experimental es analizar el impacto que tiene la profundidad de propagación estructural en el desempeño inductivo del modelo. A continuación, se muestran de manera consolidada los resultados numéricos correspondientes a cada configuración evaluada. Un análisis detallado por dataset se presenta en las subsecciones posteriores.

NL-25, L _{other} = 2			
Experiment	MRR	Hits@10	Hits@1
depth_ent_1	0.159	0.306	0.075
depth_ent_2	0.255	0.371	0.189
depth_ent_3	0.111	0.188	0.069
depth_ent_4	0.043	0.082	0.018
depth_rel_1	0.263	0.409	0.185
depth_rel_2	0.247	0.353	0.189
depth_rel_3	0.22	0.326	0.167
depth_rel_4	0.138	0.271	0.081

WK-25; L _{other} = 2			
Experiment	MRR	Hits@10	Hits@1
depth_ent_1	0.105	0.172	0.064
depth_ent_2	0.109	0.21	0.055
depth_ent_3	0.112	0.211	0.06
depth_rel_1	0.117	0.211	0.066
depth_rel_2	0.116	0.2	0.078
depth_rel_3	0.13	0.21	0.087

FN-25;L _{other} = 2			
Experiment	MRR	Hits@10	Hits@1
depth_ent_1	0.088	0.176	0.04
depth_ent_2	0.1	0.222	0.041
depth_ent_3	0.101	0.225	0.04
depth_rel_1	0.097	0.222	0.034
depth_rel_2	0.112	0.242	0.048
depth_rel_3	0.084	0.184	0.032

Table 1

Naturaleza cualitativa de los datasets

Los tres datasets evaluados provienen de fuentes con características estructurales y semánticas distintas, lo cual influye directamente en la organización de sus grafos y, potencialmente, en el comportamiento inductivo de InGram.

El dataset **NL-25** tiene su origen en NELL, un proyecto de construcción automática de conocimiento a partir de texto web. Este tipo de grafo se caracteriza por relaciones semánticas extraídas de lenguaje natural, frecuentemente con ruido y con estructuras menos regularizadas. Las relaciones tienden a reflejar patrones lingüísticos aprendidos automáticamente, lo que puede generar mayor heterogeneidad estructural y menor simetría en el grafo.

Ejemplo:

(New_York_City, locatedIn, United_States)

(Barack_Obama, presidentOf, United_States)

El dataset **WK-25**, basado en WordNet, posee una naturaleza más taxonómica y léxico-semántica. WordNet organiza conceptos mediante relaciones jerárquicas claras como hiperonimia e hiponimia. Esto produce grafos altamente estructurados, con patrones jerárquicos profundos y relaciones semánticamente bien definidas. En este contexto, la propagación estructural puede capturar información de tipo ontológico más estable y sistemática.

Ejemplo:

(red.a.01, similarTo, scarlet.a.01)

(run.v.01, entailment, move.v.01)

Por su parte, **FB-25**, derivado de Freebase, representa un grafo de conocimiento de dominio general construido de manera colaborativa. Contiene entidades del mundo real (personas, lugares, organizaciones, eventos) y relaciones factuales diversas. A diferencia de WordNet, su estructura no es estrictamente jerárquica; y a diferencia de NELL, no proviene principalmente de extracción automática de texto, sino de integración de bases

estructuradas. Esto genera un grafo heterogéneo, con alta variedad relacional y múltiples tipos de conectividad.

Ejemplo:

(Leonardo_DiCaprio, starredIn, Titanic)

(Apple_Inc, industry, Consumer_Electronics)

(United_States, currency, US_Dollar)

Característica	NL-25 (NELL)	WK-25 (WordNet)	FB-25 (Freebase)
Origen	Extracción automática desde texto web	Base léxica curada manualmente	Base enciclopédica estructurada
Tipo de grafo	Semántico abierto	Jerárquico taxonómico	Enciclopédico heterogéneo
Naturaleza de relaciones	Amplias y variadas (locatedIn, worksFor, presidentOf)	Principalmente jerárquicas (hypernym, hyponym)	Mixtas (bornIn, directedBy, industry, currency)
Regularidad estructural	Media-baja	Alta	Media
Profundidad típica de caminos	Corta a media	Larga y jerárquica	Variable
Densidad relacional	Variable (puede ser ruidosa)	Alta regularidad por categoría	Moderada
Nivel de ruido	Medio-alto (extracción automática)	Bajo (curado manualmente)	Bajo-medio
Riesgo de sobre-propagación	Alto si profundidad grande	Moderado	Alto en propagación excesiva
Comportamiento esperado con mayor profundidad	Puede degradarse por mezcla semántica	Puede beneficiarse hasta profundidad intermedia	Tiende a degradarse si se excede profundidad
Implicación para InGram	Propagación relacional corta suele ser suficiente	Profundidad intermedia puede capturar jerarquía	Profundidad moderada óptima

Table 2: Características Estructurales de las BD

Comentario analítico preliminar

Estas diferencias cualitativas son relevantes para interpretar los resultados experimentales. Un grafo con estructura jerárquica clara (como WordNet) podría beneficiarse de mayor profundidad en relaciones si las dependencias ontológicas se

extienden a múltiples niveles. En contraste, un grafo con mayor ruido estructural o heterogeneidad semántica (como NELL o Freebase) podría sufrir más rápidamente efectos de sobre-agregación cuando la profundidad aumenta.

Por tanto, la variabilidad observada en el mejor L_r entre datasets puede estar relacionada con la organización interna de sus grafos de relaciones, mientras que la relativa estabilidad de $L_e=2$ sugiere que, independientemente del dominio, las entidades tienden a requerir un contexto estructural de segundo orden para lograr un balance adecuado entre información local y contextual.

A partir del análisis conjunto entre resultados cuantitativos y naturaleza estructural de los datasets, es posible plantear algunas interpretaciones preliminares sobre el comportamiento de la profundidad en InGram.

Análisis por caso

En NL-25 (derivado de NELL), el mejor desempeño se obtiene con $L_r=1$. Dado que este grafo proviene de extracción automática de conocimiento desde texto, es razonable suponer una mayor presencia de ruido estructural y menor regularidad ontológica en el grafo de relaciones. En este contexto, una propagación profunda entre relaciones podría amplificar inconsistencias o asociaciones débiles, deteriorando la señal discriminativa. Por ello, una agregación más local en el grafo relacional parece suficiente —e incluso más estable— para capturar patrones útiles sin propagar ruido.

En WK-25 (derivado de WordNet), el mejor resultado se observa con $L_r=3$. WordNet posee una estructura altamente jerárquica y semánticamente organizada, donde las relaciones forman cadenas ontológicas coherentes. En este escenario, una mayor profundidad en el grafo de relaciones puede permitir capturar dependencias taxonómicas de orden superior, lo que favorece la propagación estructural más extensa. Aquí, la profundidad adicional parece reforzar patrones semánticos consistentes en lugar de diluirlos.

En FB-25 (derivado de Freebase), el mejor desempeño se alcanza con $L_r=2$, un punto intermedio. Freebase combina estructura factual diversa con heterogeneidad relacional, sin la rigidez jerárquica de WordNet ni el nivel de ruido potencial de NELL. Esto podría explicar por qué una profundidad moderada logra capturar suficiente contexto estructural

sin incurrir en sobre-agregación. El comportamiento intermedio de L_r es coherente con la naturaleza mixta y de dominio general del grafo.

En los tres casos, sin embargo, se mantiene relativamente estable el mejor desempeño alrededor de $L_e=2$, lo que sugiere que, independientemente del dominio, las entidades parecen requerir información estructural de segundo orden para lograr representaciones inductivas robustas. Este patrón consistente contrasta con la variabilidad observada en relaciones y refuerza la idea de que ambos sub-módulos de InGram responden de manera distinta a la expansión del contexto estructural.

Conclusión

Los resultados experimentales indican que la profundidad estructural en InGram no debe entenderse como un hiperparámetro monótonamente creciente, sino como un mecanismo de balance entre contexto y estabilidad representacional. Si bien teóricamente una mayor profundidad podría enriquecer las representaciones al incorporar dependencias de mayor alcance, en la práctica su efecto depende del tipo de nodo y de la naturaleza estructural del dataset.

El hallazgo más consistente del estudio es que las entidades presentan un punto de operación relativamente robusto en $L_e=2$, independientemente del dominio evaluado. Esto sugiere que la información de segundo orden —vecinos y vecinos de vecinos— es suficiente para capturar el contexto estructural necesario en escenarios inductivos, mientras que profundidades mayores tienden a introducir sobre-suavizado o ruido acumulativo.

En contraste, la profundidad óptima en el grafo de relaciones (L_r) varía entre datasets, lo que indica que la estructura relacional es altamente dependiente del dominio. Grafos con mayor regularidad ontológica pueden beneficiarse de mayor propagación, mientras que grafos más heterogéneos o ruidosos favorecen agregaciones más locales. Esta asimetría sugiere que los módulos de entidades y relaciones en InGram responden de manera distinta a la expansión estructural, y que la calibración de L_r debería considerarse dependiente del tipo de conocimiento representado.

Propuesta para la selección adaptativa de la profundidad estructural

Si bien los resultados experimentales permiten identificar valores adecuados de profundidad para cada dataset, el procedimiento seguido —entrenar múltiples configuraciones variando L_e y L_r — implica un costo computacional considerable. Este enfoque es viable en un entorno de investigación controlado, pero resulta poco práctico en aplicaciones reales donde el tiempo y los recursos de entrenamiento son limitados. Por tanto, surge la necesidad de mecanismos que permitan estimar una profundidad estructural adecuada sin recurrir a una búsqueda exhaustiva.

Una posible dirección consiste en analizar previamente la estructura semántica de las relaciones mediante embeddings de texto. Dado que muchas bases de conocimiento incluyen descripciones textuales de relaciones o etiquetas lingüísticas relativamente informativas, sería factible proyectarlas en un espacio vectorial semántico (por ejemplo, utilizando modelos de representación contextual). A partir de estos embeddings, podría estimarse la densidad, similitud o coherencia semántica entre relaciones antes del entrenamiento estructural.

Bajo esta idea preliminar, un grafo relacional con alta cohesión semántica —donde las relaciones presentan agrupamientos claros en el espacio vectorial— podría beneficiarse de mayor profundidad estructural, ya que la propagación tendería a reforzar patrones consistentes. En cambio, si las relaciones se distribuyen de forma dispersa o heterogénea, una profundidad menor podría evitar la propagación de ruido conceptual. Este análisis previo permitiría formular una heurística informada para seleccionar L_r (y potencialmente L_e) sin necesidad de múltiples ciclos completos de entrenamiento.

Aunque esta propuesta aún requiere formalización y validación experimental, sugiere una posible integración entre información textual y estructura gráfica como mecanismo para guiar la configuración estructural del modelo. Esto abriría una línea de trabajo orientada a la selección adaptativa de hiperparámetros basada en propiedades intrínsecas del dataset, reduciendo el costo exploratorio asociado al ajuste manual.

Referencias

- Bordes, A., Usunier, N., Garcia-Durán, A., Weston, J., & Yakhnenko, O. (2013). *Translating embeddings for modeling multi-relational data*. In **Advances in Neural Information Processing Systems** (Vol. 26). <https://papers.nips.cc/paper/2013/hash/1cecc7a77928ca8133fa24680a88d2f9-Abstract.html>
- Chen, M., Zhang, W., Geng, Y., Xu, Z., Pan, J. Z., & Chen, H. (2023). *Generalizing to unseen elements: A survey on knowledge extrapolation for knowledge graphs*. arXiv. <https://arxiv.org/abs/2302.01859>
- Hamilton, W. L., Ying, R., & Leskovec, J. (2017). *Inductive representation learning on large graphs*. In **Advances in Neural Information Processing Systems** (Vol. 30). <https://arxiv.org/abs/1706.02216>
- Hamaguchi, T., Oiwa, H., Shimbo, M., & Matsumoto, Y. (2017). *Knowledge transfer for out-of-knowledge-base entities: A graph neural network approach*. arXiv. <https://arxiv.org/abs/1706.05674>
- Lee, J., Chung, C., & Whang, J. J. (2020). *INGRAM: Inductive knowledge graph embedding via relation graphs*. In **Proceedings of the AAAI Conference on Artificial Intelligence**, 34(03), 4054–4061. <https://doi.org/10.1609/aaai.v34i03.5865>
- Nickel, M., Murphy, K., Tresp, V., & Gabrilovich, E. (2016). *A review of relational machine learning for knowledge graphs*. **Proceedings of the IEEE**, 104(1), 11–33. <https://doi.org/10.1109/JPROC.2015.2483592>
- Schlichtkrull, M., Kipf, T. N., Bloem, P., van den Berg, R., Titov, I., & Welling, M. (2018). *Modeling relational data with graph convolutional networks*. In **The Semantic Web – ESWC 2018** (Lecture Notes in Computer Science, Vol. 10843, pp. 593–607). Springer. https://doi.org/10.1007/978-3-319-93417-4_38
- Teru, K. K., Denis, E., & Hamilton, W. L. (2020). Inductive relation prediction by subgraph reasoning. In *Proceedings of the 37th International Conference on Machine Learning* (pp. 9448–9457). PMLR. <https://arxiv.org/abs/1911.06962>