



Tecnológico de Monterrey

Maestría en Inteligencia Artificial Aplicada

Análisis de Grafos y Extrapolación de Conocimiento para
identificar Relaciones No Explícitas de información

Investigación

Profesor Dr. Gerardo Jesús Camacho González

Profesor Dr. Eusebio Vargas Estrada

Equipo 32

José Adan Vega Pérez	A01796093
Silvia Xochitl Ibañez Vara	A01795200
Diego Andrés Bernal Díaz	A01795975

Introducción.....	4
Antecedentes.....	5
Knowledge Graph Embeddings	5
Redes neuronales sobre grafos	6
Modelos inductivos para grafos de conocimiento	7
Extrapolación de conocimiento en grafos	7
Planteamiento.....	8
Metodología.....	9
Modelo inductivo basado en vecindario: IKGE	9
Modelo basado en propagación estructural: InGram.....	10
Propagación estructural	10
Profundidad de propagación estructural.....	11
Configuración Experimental.....	12
InGram	12
Escenario experimental y selección de datasets	12
Arquitectura del modelo y parámetros explorados.....	12
IKGE.....	13
Escenario experimental y selección de datasets	13
Arquitectura del modelo y parámetros explorados.....	14
Puerta Suave (Soft Floor Gate) en el Type Matching.....	14
Función de Pérdida: De BCE a Hinge Ranking Loss.....	15
Subgrafos K-hop BFS	15
El "Atajo Estructural" en el Muestreo Negativo	15
Hiperparámetros No Declarados:	15
Métricas de evaluación.....	16
Infraestructura computacional.....	17
Características estructurales de los grafos.....	17
Resultados.....	18
InGram	18
IKGE.....	18
Discusión	20
Diferencias entre Ingram vs IKGE	20
Impacto de la estructura del grafo	20
Efecto de la profundidad L1, L2, L3.....	20
InGram	20
IKGE.....	21
Consideraciones para la Selección Adaptativa de profundidad.....	22
Motivación para selección adaptativa	22
Enfoque para selección adaptativa	22

Conclusión.....	25
Trabajo Futuro.....	¡Error! Marcador no definido.
Aplicación en grafos más grandes.....	¡Error! Marcador no definido.
Automatización de selección de profundidad.....	¡Error! Marcador no definido.
Evaluación en otros dominios de conocimiento	¡Error! Marcador no definido.
Referencias.....	26

Introducción

Los grafos de conocimiento se han consolidado como una herramienta fundamental para representar información relacional en diversos dominios, incluyendo sistemas de recomendación, recuperación de información, análisis semántico y procesamiento de lenguaje natural. En estos sistemas, el conocimiento se modela comúnmente mediante tripletas de la forma (h, r, t) , donde h representa la entidad origen (head), r la relación y t la entidad destino (tail). Esta representación permite capturar relaciones complejas entre entidades y facilita tareas de inferencia como la predicción de enlaces dentro del grafo.

En los últimos años, los métodos de Knowledge Graph Embedding (KGE) han sido ampliamente utilizados para aprender representaciones vectoriales continuas de entidades y relaciones, permitiendo aplicar técnicas de aprendizaje automático sobre estructuras relacionales (Bordes et al., 2013; Wang et al., 2017). Estos modelos proyectan entidades y relaciones en un espacio latente donde las relaciones semánticas pueden modelarse mediante funciones de puntuación sobre tripletas. Sin embargo, la mayoría de los enfoques tradicionales asumen que el conjunto de entidades y relaciones permanece fijo durante el entrenamiento, lo cual limita su capacidad para adaptarse a grafos de conocimiento dinámicos donde nuevos elementos pueden aparecer con el tiempo (Nickel et al., 2016).

Para abordar esta limitación, investigaciones recientes han explorado el problema de la extrapolación de conocimiento en grafos, cuyo objetivo es permitir que los modelos generalicen hacia entidades previamente no observadas durante el entrenamiento (Chen et al., 2023). Este escenario se conoce comúnmente como Out-of-Knowledge-Base (OOKB) y plantea el desafío de generar representaciones para nuevas entidades a partir de la estructura del grafo disponible. A diferencia de los enfoques transductivos tradicionales, los métodos inductivos buscan derivar embeddings a partir del contexto estructural de las entidades dentro del grafo.

Entre los enfoques propuestos para abordar este problema, Inductive Knowledge Graph Embedding (IKGE) genera representaciones para entidades no vistas a partir de su vecindario estructural, permitiendo extender el modelo a nuevas entidades sin necesidad de reentrenamiento completo (Oh et al., 2022). Mientras que, InGram introduce un mecanismo inductivo basado en propagación estructural y grafos de relaciones que permite reconstruir representaciones tanto para entidades como para relaciones a partir de la conectividad del grafo (Lee et al., 2020). A diferencia de los modelos que dependen únicamente del subgrafo local, InGram incorpora mecanismos de propagación estructural que permiten capturar contexto relacional más amplio.

En este trabajo se realiza un análisis comparativo entre IKGE e InGram en escenarios de extrapolación de conocimiento donde emergen entidades no vistas. Los experimentos se realizan sobre tres datasets derivados de grafos de conocimiento con características estructurales distintas, lo que permite analizar cómo la estructura del grafo influye en la capacidad de generalización de los modelos inductivos.

Adicionalmente, se analiza el impacto de la profundidad de propagación estructural en InGram, evaluando configuraciones de profundidad L1, L2 y L3 tanto en el módulo de entidades como en el módulo de relaciones del modelo. Este análisis permite estudiar cómo diferentes niveles de contexto estructural afectan el desempeño del modelo en distintos tipos de grafos de conocimiento.

Las principales contribuciones de este trabajo son las siguientes:

1. Un análisis comparativo entre IKGE e InGram en escenarios de extrapolación de conocimiento con entidades no vistas.
2. Un estudio empírico del efecto de la profundidad de propagación estructural en InGram, evaluando configuraciones L1, L2 y L3 en los módulos de entidades y relaciones.
3. Evidencia experimental de que el comportamiento de la profundidad óptima depende de las características estructurales del grafo de conocimiento.
4. Un análisis interpretativo que relaciona el desempeño de los modelos con la naturaleza estructural de distintos grafos de conocimiento.
5. Una discusión conceptual sobre los elementos necesarios para una futura selección adaptativa de profundidad en modelos inductivos de grafos de conocimiento.

Antecedentes

Knowledge Graph Embeddings

Los grafos de conocimiento representan información mediante estructuras relacionales que capturan entidades y las relaciones entre ellas. Se define un grafo de conocimiento como

$$G = (E, R, T)$$

Formalmente, un grafo de conocimiento se compone de tripletas de la forma:

$$(h, r, t)$$

Donde h representa la entidad de origen (head), r la relación, t la entidad destino (tail)

Este tipo de representación permite modelar relaciones complejas entre entidades y construye la base para tareas de inferencia como la predicción de enlaces.

Con el objetivo de aplicar métodos de aprendizaje automático sobre grafos de conocimiento, se han desarrollado técnicas de Knowledge Graph Embedding (KGE), cuyo propósito es aprender representaciones vectoriales continuas de entidades y relaciones en un espacio latente φ_X , (Wang et al., 2017). En este espacio, las relaciones semánticas entre entidades pueden modelarse mediante funciones score:

$$f(h, r, t)$$

que evalúan la plausibilidad de las tripletas.

Uno de los enfoques más influyentes en esta línea es TransE, propuesto por Bordes et al. (2013), que modela las relaciones como operaciones de traslación en el espacio vectorial.

$$f(h, r, t) = -|\mathbf{e}_h + \mathbf{r} - \mathbf{e}_t|$$

La idea es que una tripleta válida cumple aproximadamente:

$$\mathbf{e}_h - \mathbf{r} \approx \mathbf{e}_t$$

En este modelo, una relación $\mathbf{r}$ se interpreta como una transformación que conecta la representación de la entidad origen con la entidad destino en el espacio de embeddings. Este enfoque dio origen a una amplia familia de modelos translacionales que buscan capturar diferentes tipos de patrones relacionales en grafos de conocimiento.

A pesar de su éxito en tareas de predicción de enlaces, estos modelos presentan una limitación importante: generalmente operan bajo un escenario transductivo, en el cual el conjunto de entidades y relaciones se asume fijo durante el entrenamiento. Como consecuencia, cuando aparecen nuevas entidades en el grafo, el modelo no puede generar representaciones adecuadas sin realizar un reentrenamiento completo (Nickel et al., 2016)

Redes neuronales sobre grafos

Con el objetivo de incorporar información estructural del grafo de manera más explícita, diversas investigaciones han explorado el uso de Graph Neural Networks (GNN) para el aprendizaje de representaciones en grafos de conocimiento. Las GNN permiten propagar información entre nodos vecinos mediante mecanismos de agregación que capturan dependencias estructurales en el grafo.

Dentro de este enfoque, Relational Graph Convolutional Networks (RGCN) introducen una extensión de las redes convolucionales sobre grafos que considera explícitamente la naturaleza multirrelacional de los grafos de conocimiento (Schlichtkrull et al., 2018). En este modelo, cada relación del grafo se asocia con una transformación específica que permite modelar distintos tipos de interacciones entre entidades.

El uso de GNN ha permitido mejorar el modelado de dependencias estructurales en grafos de conocimiento. Sin embargo, muchos de estos modelos continúan operando bajo supuestos transductivos y dependen de representaciones previamente aprendidas para cada entidad, lo cual limita su capacidad de generalizar a entidades que no han sido observadas durante el entrenamiento.

Modelos inductivos para grafos de conocimiento

Para superar las limitaciones de los enfoques transductivos, investigaciones recientes han propuesto modelos inductivos capaces de generar representaciones para entidades previamente no observadas. En estos enfoques, los embeddings no se asocian directamente a identificadores específicos de entidades, sino que se generan a partir del contexto estructural del grafo.

Uno de los enfoques en esta línea es Inductive Knowledge Graph Embedding (IKGE), propuesto por Oh et al. (2022). Este método genera embeddings para entidades no vistas utilizando información proveniente de su vecindario estructural dentro del grafo. De esta forma, las representaciones pueden derivarse a partir de las relaciones y entidades conectadas, permitiendo extender el modelo a nuevas entidades sin necesidad de reentrenamiento completo.

Por otra parte, el modelo InGram introduce un enfoque inductivo basado en propagación estructural que busca capturar patrones relacionales de mayor alcance (Lee et al., 2020). A diferencia de los métodos que dependen únicamente del subgrafo local de una entidad, InGram incorpora un grafo de relaciones que permite modelar interacciones entre diferentes tipos de relaciones presentes en el grafo de conocimiento. Mediante este mecanismo, el modelo puede reconstruir representaciones tanto para entidades como para relaciones a partir de la estructura del grafo.

Este tipo de enfoque permite capturar contextos estructurales más amplios y ofrece una mayor capacidad de generalización en escenarios donde aparecen nuevas entidades.

Extrapolación de conocimiento en grafos

El problema de generar representaciones para elementos previamente no observados en un grafo de conocimiento se conoce comúnmente como extrapolación de conocimiento. Este escenario surge cuando el grafo evoluciona con el tiempo y aparecen nuevas entidades o relaciones que no estaban presentes durante el entrenamiento del modelo.

Este problema ha sido ampliamente estudiado en la literatura reciente y suele denominarse Out-of-Knowledge-Base (OOKB). En este contexto, el objetivo consiste en permitir que los modelos aprendan mecanismos de representación capaces de generalizar más allá de las entidades y relaciones observadas inicialmente (Chen et al., 2023).

Diversos enfoques han sido propuestos para abordar este desafío, incluyendo métodos basados en subgrafos, mecanismos de razonamiento estructural y modelos inductivos capaces de generar embeddings dinámicamente a partir del contexto del grafo. Estas investigaciones reflejan una tendencia creciente hacia modelos que priorizan la capacidad de generalización estructural en grafos de conocimiento dinámicos.

En este contexto, el estudio comparativo de distintos enfoques inductivos y el análisis de los mecanismos que influyen en su capacidad de generalización constituyen un área activa de investigación en el campo de los grafos de conocimiento.

Planteamiento

Los grafos de conocimiento representan información mediante estructuras relacionales formadas por entidades y las relaciones entre ellas. Formalmente, un grafo de conocimiento se define como:

$$G = (E, R, T)$$

Donde:

- $e \in E$, el conjunto de entidades
- $r \in R$, es el conjunto de relaciones
- $t \in T$, es el conjunto de tripletas

Cada tripleta tiene la forma:

$$(h, r, t)$$

Donde $h, t \in E$, representan la entidad origen (*head*) y la entidad destino (*tail*), mientras que $r \in R$, corresponde al tipo de relación que conecta ambas entidades.

En los métodos de Knowledge Graph Embedding, el objetivo consiste en aprender representaciones vectoriales continuas de entidades y relaciones en un espacio latente de dimensión d . Estas representaciones se obtienen mediante funciones de embedding que asignan a cada entidad y relación un vector en el espacio:

$$\varphi_E: E \rightarrow \mathbb{R}^d$$

$$\varphi_R: R \rightarrow \mathbb{R}^d$$

De esta manera, cada entidad $e \in E$ se representa mediante un vector $e = \varphi_E(e)$, mientras que cada relación $r \in R$ $r = \varphi_R(r)$.

Estas representaciones permiten evaluar la plausibilidad de una tripleta mediante una función score:

$$f(h, r, t) = f(\varphi_E(h), \varphi_R(r), \varphi_E(t))$$

donde valores más altos indican una mayor probabilidad de que la tripleta corresponda a una relación válida en el grafo de conocimiento.

En los enfoques tradicionales de embeddings para grafos de conocimiento, las representaciones vectoriales se aprenden directamente para cada entidad presente en el conjunto de entrenamiento. Este supuesto implica que el conjunto de entidades es fijo durante el proceso de aprendizaje. Como consecuencia, cuando aparecen nuevas entidades que no fueron observadas durante el entrenamiento, el modelo no puede generar representaciones adecuadas para ellas sin realizar un nuevo proceso de entrenamiento.

Este escenario da lugar al problema conocido como Out-of-Knowledge-Base (OOKB), en el cual el modelo debe ser capaz de generar representaciones para entidades previamente no observadas utilizando únicamente la información estructural disponible en el grafo de conocimiento.

Para abordar este desafío, los modelos inductivos buscan aprender funciones de representación capaces de generar embeddings para nuevas entidades a partir de su contexto estructural dentro del grafo. En lugar de asociar directamente un vector a cada entidad, estos enfoques utilizan la estructura del grafo y las relaciones entre entidades para inferir representaciones dinámicamente.

En este trabajo se estudia el problema de extrapolación de conocimiento en grafos donde aparecen **nuevas entidades**, analizando el comportamiento de distintos enfoques inductivos capaces de generar representaciones para entidades no vistas a partir de la estructura del grafo de conocimiento.

Metodología

En este trabajo se estudia el problema de extrapolación de conocimiento en grafos donde aparecen entidades que no fueron observadas durante el entrenamiento. Formalmente, el conjunto de entidades del grafo puede dividirse en dos subconjuntos:

$$E = E_{train} \cup E_{new}$$

Donde E_{train} corresponde a las entidades observadas durante el entrenamiento y E_{new} representa las entidades que aparecen únicamente en los conjuntos de validación o prueba.

El objetivo consiste en evaluar la capacidad de distintos modelos para generar embeddings para entidades pertenecientes a E_{new} utilizando únicamente el grafo y la información relacional disponible.

Modelo inductivo basado en vecindario: IKGE

Los modelos de Inductive Knowledge Graph Embedding (IKGE) generan representaciones para entidades no vistas utilizando la información estructural de su vecindario en el grafo.

En este enfoque, el embedding de una entidad se obtiene mediante una función que depende del contexto relacional de la entidad dentro del grafo:

$$e_i = \varphi(E_i, N(i))$$

donde $N(i)$ representa el conjunto de entidades y relaciones conectadas con la entidad i . De esta manera, el embedding no depende directamente de un identificador específico de entidad, sino de las interacciones estructurales que dicha entidad mantiene en el grafo de conocimiento. Este mecanismo permite generar representaciones para entidades previamente no observadas, siempre que exista información relacional disponible en su vecindario.

Modelo basado en propagación estructural: InGram

El modelo InGram propone un enfoque inductivo basado en la propagación estructural de información a través del grafo de conocimiento. A diferencia de métodos que utilizan únicamente el vecindario local de cada entidad, InGram incorpora dos niveles de representación estructural:

1. Propagación entre entidades
2. Propagación entre relaciones

Para capturar dependencias entre relaciones, el modelo introduce un grafo de relaciones definido como:

$$G = (R, E_r)$$

donde los nodos corresponden a relaciones presentes en el grafo de conocimiento y las aristas representan interacciones estructurales entre relaciones observadas en las tripletas

Este mecanismo permite modelar patrones relacionales más complejos y facilita la propagación de información semántica entre diferentes tipos de relaciones.

El modelo aprende representaciones tanto para entidades como para relaciones mediante procesos iterativos de propagación estructural.

Propagación estructural

Durante el proceso de aprendizaje, las representaciones se actualizan mediante iteraciones de propagación que agregan información proveniente de los vecinos estructurales.

Para las entidades, las representaciones se actualizan utilizando información de las entidades conectadas a través de las relaciones del grafo:

$$e_i^{(l+1)} = \sigma \left(\sum_{(i,r,j) \in T} W_r e^{(l)} \right)$$

Donde:

- l es la propagación
- W_r es una transformación asociada a la relación r
- σ es una función de activación no lineal

De manera análoga, las representaciones de las relaciones se actualizan mediante agregación sobre el grafo de relaciones:

$$r_i^{(l+1)} = \sigma \left(\sum_{r' \in N(r)} W r'^{(l)} \right)$$

Donde $N(r)$ representa el conjunto de relaciones vecinas en el grafo de relaciones.

Profundidad de propagación estructural

La propagación estructural en InGram puede aplicarse durante múltiples iteraciones. La profundidad de propagación determina cuántas capas de agregación estructural se utilizan para actualizar las representaciones.

En este trabajo se evalúan configuraciones con diferentes niveles de profundidad:

$$L \in \{1, 2, 3\}$$

Donde L indica el número de iteraciones de propagación estructural aplicadas durante el aprendizaje del modelo.

El objetivo de este análisis consiste en analizar cómo la profundidad de propagación influye en la capacidad del modelo para capturar dependencias estructurales y generar representaciones adecuadas para entidades no vistas.

Configuración Experimental

InGram

En esta sección se describe la configuración experimental utilizada para evaluar el modelo InGram bajo diferentes configuraciones de profundidad en la agregación de información estructural. Para ello se realizaron múltiples ejecuciones del modelo variando el número de capas asociadas a entidades y relaciones, mientras que el resto de los hiperparámetros se mantuvo constante de acuerdo con la implementación original. El desempeño del modelo se evaluó mediante tareas de predicción de enlaces.

Escenario experimental y selección de datasets

Los experimentos se realizaron utilizando los conjuntos de datos proporcionados en el repositorio oficial de InGram, específicamente las variantes NL-25, WK-25 y FB-25, derivadas de los grafos de conocimiento NELL, WordNet y Freebase, respectivamente. Estos conjuntos fueron diseñados para evaluar modelos en escenarios inductivos de grafos de conocimiento.

En estas configuraciones, aproximadamente el 25% de las entidades del grafo aparecen únicamente en los conjuntos de validación y prueba, mientras que el modelo se entrena únicamente con las entidades presentes en el conjunto de entrenamiento. Este tipo de partición permite evaluar la capacidad de los modelos para generar representaciones para entidades previamente no observadas, utilizando únicamente la información estructural disponible en el grafo.

La división de los datos en conjuntos de entrenamiento, validación y prueba se utilizó exactamente como se define en la implementación original de InGram, sin realizar modificaciones adicionales. Esto permite mantener la comparabilidad con los resultados reportados en trabajos previos que utilizan estos mismos conjuntos de evaluación.

Arquitectura del modelo y parámetros explorados

Los experimentos se realizaron utilizando la arquitectura original del modelo InGram, sin modificaciones estructurales. El objetivo de la experimentación fue analizar el efecto de la profundidad de propagación estructural en los módulos de entidades y relaciones del modelo.

Para ello se realizaron conjuntos de experimentos independientes en los que se varió el número de capas asociadas a la profundidad de agregación en entidades y relaciones. En cada experimento se modificó únicamente uno de estos parámetros, mientras que el otro se mantuvo fijo en su valor por defecto. De esta manera, al evaluar la profundidad de entidades se mantuvo constante la profundidad de relaciones, y viceversa, lo que permite aislar el efecto de cada componente del modelo sobre el desempeño en la tarea de predicción de enlaces.

El resto de los hiperparámetros del modelo, incluyendo la dimensionalidad de los embeddings, la tasa de aprendizaje, el número de ejemplos negativos y los parámetros de entrenamiento, se mantuvieron en los valores definidos por la implementación original del repositorio de InGram.

Esto permite asegurar que las diferencias observadas en los resultados se deben únicamente a las variaciones en la profundidad del modelo.

IKGE

Debido a la falta de código oficial publicado por parte de los autores del estudio original, se elaboró desde cero una implementación propia del código siguiendo los parámetros estructurales del modelo propuestos dentro del estudio. Esta, consiste en una arquitectura inductiva de mundo abierto (open-world). En lugar de aprender un vector estático por entidad, IKGE utiliza modelos de embeddings pre-entrenados, extrae características a partir de descripciones textuales y metadatos (nombres, restricciones de tipos), y posteriormente enriquece estas características mediante una red neuronal convolucional de grafos (GCN) basada en atención, agregando el contexto topológico a múltiples saltos (K-hops).

Este proceso nos llevó a entender varios vacíos de reproducibilidad en el paper original, sobretodo con respecto al proceso de entrenamiento y prueba de la arquitectura elegida. Pero a la vez nos llevó a conclusiones sobre el uso real de este modelo dentro de distintos tipos de grafos de conocimiento. Dentro de los experimentos que se llevaron a cabo se configuraron varias opciones de funciones de pérdida, modelos pre-entrenados de embeddings y un cambio estructural en la función de type matching propuesta originalmente.

Escenario experimental y selección de datasets

Para llevar a cabo esta actividad, decidimos recompilar versiones propias de los datasets DBpedia50k+ y FB20k+, a partir de las versiones disponibles en línea de sus proveedores. Esto con el fin de poder entender si el código propuesto llegaría a los mismos resultados publicados y tener un punto de comparación fiable entre nuestra implementación y la arquitectura propuesta. A partir de esta información conseguida se armaron datasets con los tamaños más cercanos posibles a los publicados dentro de la publicación original.

En un primer acercamiento decidimos implementar el dataset de DBpedia50k + debido a que su tamaño más pequeño que el resto nos permitiría hacer entrenamientos cortos y pruebas más rápidas que con otros datasets más grandes. Después de revisar que la arquitectura del paper fuera lo más cercana a la propuesta y encontrar que los resultados no se acercaban a los publicados, decidimos revisar la premisa de IKGE en cuanto a los modelos de embeddings preentrenados utilizados y encontramos que GloVE (Pennington et al., 2014) apenas alcanzaba una cobertura de nuestro vocabulario de al rededor de 27%. Por lo que decidimos cambiar al modelo wikipedia2vec (Yamada et al., 2020) así como aplicar lematización al vocabulario del grafo, ambas soluciones utilizadas por el paper original. De este modo logramos subir la cobertura del modelo de embeddings a un valor cercano al 85%.

Esta hipótesis resultó cuando menos insuficiente al mantener pésimos resultados con respecto a la publicación original. Por lo tanto, inspirados en la metodología CRISP-ML, decidimos devolvemos a analizar el dataset elegido y plantear una segunda hipótesis con respecto a la disparidad de resultados: IKGE necesita que su grafo de conocimiento contenga un número amplio de relaciones por entidad. Nuestra implementación de DBpedia50k+ contenía un aproximado de 2,7 relaciones por entidad, y ante la imposibilidad de recuperar fuentes de la página oficial de DBpedia que la publicación original haya podido usar, decidimos armar el dataset de FB20k+ sobre la misma premisa de hacer la misma relación numérica con las características publicadas. Este nuevo dataset contiene una densidad de 67 relaciones en promedio por entidad y es la hipótesis que nos permitió llegar a resultados comparables con la publicación original.

Arquitectura del modelo y parámetros explorados

La implementación de este modelo requirió la construcción de 4 scripts diferentes que recrean la arquitectura propuesta por el paper, siguiendo criterios de modularidad: LineGraph, que conforma el grafo lineal propuesto en el artículo con las relaciones extendidas del módulo, FactFeatureExtractor que extrae el vocabulario, lematiza y guarda el vocabulario para usarlo también en la etapa de evaluación, AttentiveAggregator que crea la función de atención según la fórmula propuesta en el paper y TrainIKGE que orquesta, entrena y evalúa el modelo final.

Para lograr que el modelo convergiera, tuvimos que desviarnos de la formulación estricta del artículo en tres puntos fundamentales:

Puerta Suave (Soft Floor Gate) en el Type Matching

La Ecuación 5 del artículo dicta una compuerta lógica (multiplicación por 0 o 1) para el Type Matching: si los tipos de la entidad no contienen la restricción de dominio/rango de la relación exacta, la característica generada se vuelve un vector cero. El problema que encontramos con esta formulación es que la ontología de DBpedia y Freebase es jerárquica (por ejemplo, dbo:President satisface la restricción dbo:Person, pero una intersección plana (flat intersection) de tensores arroja 0) agregado al problema de densidad de relaciones por entidad ya descrito. Nuestros diagnósticos mostraron que el 87.4% de los gradientes colapsaban a 0 en la primera época debido a esta formulación ingenua. Para compensar este problema, implementamos una puerta suave o soft floor: $\text{type_gate} = 0.1 + 0.9 * \text{type_validity}$. Si no hay coincidencia directa, el modelo retiene un 10% de la señal original de la GCN. Esto permite el flujo del gradiente a través de las jerarquías ontológicas no explícitas. Adicionalmente, permitimos una validez de 1.0 si la entidad carece por completo de tipos registrados.

Función de Pérdida: De BCE a Hinge Ranking Loss

El paper entrena usando Binary Cross-Entropy (BCE) (Ecuación 13). Al inicio, observamos que las predicciones colapsaban alrededor de un logit de 0 (sigmoide aproximado de 0.5), provocando que los gradientes positivos y negativos se cancelaran mutuamente. * Para solucionarlo, migramos a una Hinge Margin Ranking Loss con un margen de 0.5. La pérdida penaliza al modelo solo si la diferencia entre la puntuación positiva y la negativa no supera el margen: $L = \max(0, \text{margin} - \text{score}\{\text{pos}\} + \text{score}\{\text{neg}\})$. Esto reactivó la dinámica de aprendizaje obligando al modelo a crear un "gap" de separabilidad.

Subgrafos K-hop BFS

En `train_ikge_w2v.py`, construimos un muestreo BFS (Breadth-First Search) alrededor de la tripleta objetivo para construir el vecindario $\{N\}(f_u)$. La tripleta a predecir se inserta dinámicamente como un nodo virtual durante el entrenamiento para evitar fugas de datos (data leakage), acoplándose perfectamente con la formulación de inferencia del paper. Sin embargo, encontramos que el valor K-hop propuesto por el paper, y directamente comparable con nuestra investigación sobre el modelo de InGram como la profundidad de agregación puede resultar excesiva. Nuestras pruebas indican que un K-hop de 2 tanto para el dataset de DBpedia50k como para el FB20k son suficientes para conseguir resultados comparables.

Adicional a esto encontramos que el artículo carece de detalles de ingeniería algorítmica, en donde catalogamos un total de 16 brechas encontradas. Destacamos las de criticidad alta:

El "Atajo Estructural" en el Muestreo Negativo

El artículo indica: "generate negative triples by randomly replacing head or tail entity". No especifica la población candidata. Nuestro error inicial fue muestrear aleatoriamente entre todas las 19k entidades (incluidas las Out-of-KG). Dado que las entidades OOKG tienen un subgrafo vacío por definición, el modelo aprendió rápidamente la regla trivial: "Si no tiene vecinos, es una tripleta falsa". El MRR en validación saltó a 0.35 en la época 3, pero el MRR en full-ranking real colapsó a 0.017. Por lo tanto restringimos el muestreo negativo exclusivamente a entidades In-KG. Además, construimos cubetas por restricciones de tipo (type-constrained buckets). Al inyectar como negativos a entidades In-KG que comparten el mismo tipo que la respuesta correcta, forzamos a la red a utilizar el texto de Wikipedia para discriminar verdaderos de falsos.

Hiperparámetros No Declarados:

- Batch Size: No documentado. Asumimos 256 tras ensayos heurísticos de uso de memoria VRAM (aprox. 14GB en GPU).

- **Duración del Entrenamiento:** Configuramos 200 épocas con Cosine Annealing LR (scheduler propuesto por el paper, pero sin mencionar el número real de ciclos de entrenamiento usados) deteniéndonos por medio de Early Stopping basado en la pérdida de la partición de validación durante entrenamiento. En este punto también queremos aclarar que debido a la falta de recursos decidimos detener el entrenamiento del modelo final de FB20k a los 30 epochs, sin evidencia de que se haya alcanzado el punto de overfitting, debido a que más ciclos de entrenamiento resultaban costosos para la demostración de nuestra segunda hipótesis. Nuestro modelo a 30 épocas de entrenamiento lograba pérdida comparable a la del DBpedia50k cuando este último entrenó por 63 epochs.

Métricas de evaluación

El desempeño de ambos modelos se evaluó utilizando métricas estándar en tareas de predicción de enlaces en grafos de conocimiento. En particular, se utilizaron las métricas Mean Reciprocal Rank (MRR), Hits@10 y Hits@1, que permiten evaluar la capacidad del modelo para posicionar correctamente la entidad objetivo dentro del ranking de predicciones.

La métrica MRR mide el promedio del inverso de la posición en la que aparece la respuesta correcta dentro del ranking generado por el modelo.

$$MRR = \frac{1}{N} \sum_{i=1}^N \frac{1}{rank_i}$$

Donde $rank_i$ corresponde a la posición de la entidad correcta en el ranking generado para la tripleta i y N es el número total de evaluadas. Esta métrica proporciona una medida global del desempeño del sistema al considerar la calidad del ordenamiento completo de las predicciones.

Por su parte, Hits@ k mide la proporción de casos en los que la entidad correcta aparece dentro de las primeras k posiciones del ranking. En este trabajo se reportan Hits@10 y Hits@1, definidos como:

$$Hits@k = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(rank_i \leq k)$$

Donde $\mathbb{I}(\bullet)$ es una función indicadora que toma valor 1 cuando la condición se cumple y 0 en caso contrario.

Estas métricas permiten evaluar tanto la calidad global del ranking generado por el modelo (MRR) como su capacidad para ubicar la entidad correcta entre las primeras posiciones del ranking (Hits@ k).

Infraestructura computacional

Los experimentos se ejecutaron en un entorno de cómputo con soporte para aceleración mediante GPUs como la RTX6000Ada para el modelo de InGram y las RTX 5060ti, 5070ti y 3090 para el modelo de IKGE, utilizando el framework PyTorch para la implementación y entrenamiento del modelo. La disponibilidad de recursos de cómputo acelerado permitió realizar múltiples ejecuciones del modelo bajo distintas configuraciones de profundidad en tiempos razonables.

Destacamos también que para realizar la implementación del modelo IKGE utilizamos el modelo LLM Claude Sonnet 4.6 a través de Github Copilot for students en VS Code conectado a contenedores de GPUs remotas por conexiones SSH. Su uso fue de generación dirigida por el usuario sobre cada una de las secciones del documento original, creación de bitácoras de implementación y solución de problemas varios relacionados con el código.

Características estructurales de los grafos

Característica	NL-25 (NELL)	WK-25 (WordNet)	FB-25 (Freebase)
Origen	Extracción automática desde texto web	Base léxica curada manualmente	Base enciclopédica estructurada
Tipo de grafo	Semántico abierto	Jerárquico taxonómico	Enciclopédico heterogéneo
Naturaleza de relaciones	Amplias y variadas (locatedIn, worksFor, presidentOf)	Principalmente jerárquicas (hypernym, hyponym)	Mixtas (bornIn, directedBy, industry, currency)
Regularidad estructural	Media-baja	Alta	Media
Profundidad típica de caminos	Corta a media	Larga y jerárquica	Variable
Densidad relacional	Variable (puede ser ruidosa)	Alta regularidad por categoría	Moderada
Nivel de ruido	Medio-alto (extracción automática)	Bajo (curado manualmente)	Bajo-medio
Riesgo de sobre-propagación	Alto si profundidad grande	Moderado	Alto en propagación excesiva
Comportamiento esperado con mayor profundidad	Puede degradarse por mezcla semántica	Puede beneficiarse hasta profundidad intermedia	Tiende a degradarse si se excede profundidad
Implicación para InGram	La propagación profunda puede amplificar ruido semántico debido a la extracción automática; una profundidad moderada suele ser suficiente para capturar señales útiles	La estructura jerárquica favorece la propagación estructural, permitiendo que profundidades intermedias capturen relaciones taxonómicas	La diversidad relacional permite capturar contexto estructural amplio, pero profundidades excesivas pueden mezclar señales heterogéneas
Implicación para IKGE	Puede verse afectado por ruido en vecinos debido a extracción automática; la calidad del subgrafo local es crítica para generar embeddings fiables	La estructura jerárquica y las relaciones consistentes favorecen la generación de embeddings inductivos a partir de vecinos	El subgrafo local suele ser informativo, pero la heterogeneidad de relaciones puede introducir señales mixtas en la generación de embeddings

Resultados

Resultados InGram

A continuación se presentan los resultados obtenidos en los experimentos realizados con el modelo InGram sobre los conjuntos de datos NL-25, WK-25 y FB-25. En todos los casos se mantuvo fija la profundidad de uno de los componentes del modelo en su valor por defecto ($L=2$), mientras que la profundidad del otro componente se varió de forma independiente para analizar su impacto en el desempeño del modelo. De esta manera, los experimentos etiquetados como `depth_ent_k` corresponden a configuraciones en las que se varió la profundidad de agregación de entidades, mientras que los experimentos `depth_rel_k` modifican la profundidad de agregación de relaciones. Los resultados se reportan utilizando las métricas MRR, Hits@10 y Hits@1.

NL-25, $L_{\text{other}} = 2$				WK-25, $L_{\text{other}} = 2$				FB-25, $L_{\text{other}} = 2$			
Experiment	MRR	H@10	H@1	Experiment	MRR	H@10	H@1	Experiment	MRR	H@10	H@1
depth_ent_1	0.159	0.306	0.075	depth_ent_1	0.105	0.172	0.064	depth_ent_1	0.088	0.176	0.04
depth_ent_2	0.255	0.371	0.189	depth_ent_2	0.109	0.21	0.055	depth_ent_2	0.1	0.222	0.041
depth_ent_3	0.111	0.188	0.069	depth_ent_3	0.112	0.211	0.06	depth_ent_3	0.101	0.225	0.04
depth_ent_4	0.043	0.082	0.018	depth_rel_1	0.117	0.211	0.066	depth_rel_1	0.097	0.222	0.034
depth_rel_1	0.263	0.409	0.185	depth_rel_2	0.116	0.2	0.078	depth_rel_2	0.112	0.242	0.048
depth_rel_2	0.247	0.353	0.189	depth_rel_3	0.13	0.21	0.087	depth_rel_3	0.084	0.184	0.032
depth_rel_3	0.22	0.326	0.167								
depth_rel_4	0.138	0.271	0.081								

Resultados IKGE

Estos fueron los resultados obtenidos en la implementación de IKGE con el dataset de FB20k. El análisis se desglosa en la clasificación en los 4 Grupos de Evaluación dictados por el artículo, probando las 85,557 tripletas del conjunto de prueba en forma vectorizada sobre GPU. Los resultados sintetizan la capacidad del modelo para adivinar el nodo (o relación) faltante, evaluado mediante Mean Reciprocal Rank (MRR) y Mean Rank (MR).

Grupo de Evaluación del Paper	Patrones O/X Evaluados	Nº Tripletas	MRR Obtenido	Mean Rank	Objetivo MRR (FB20k+)	Diagnóstico
Group 1 - Head Pred.	O-O-X, O-X-X, O-X-O	13,105	0.3064	552.8	0.39	Sólido teniendo la posibilidad de hacer mas epocas de entrenamiento
Group 2 - Tail Pred.	X-O-O, X-X-O, O-X-O	20,272	0.3771	165.7	0.4	Sólido; la predicción de cola con texto rinde bien.
Group 3 - Head+Tail OOK	O-O-X (H), X-O-O (T)	26,085	0.4053	49	0.42	Sólido; El muestreo negativo permite al modelo generalizar a entidades OOKG.
Group 4 - Relation Pred.	O-O- X, X-O-O, X-O-X	26,095	0.0396	413.1	0.36	Subóptimo (Colapso por Bug en el entrenamiento).
Nota sobre notación del paper original: (Head-Relation-Tail), donde O = In-KG (Conocido) y X = Out-of-KG (Desconocido).						

Adicional a las tablas del artículo original, diseñamos un experimento de clasificación binaria para determinar con otras métricas las capacidades de generalización del modelo. Tras calibrar el umbral óptimo con el valor de pérdida visto durante el entrenamiento en el subconjunto de validación ($\tau = 0.38$), probamos un set balanceado (1:1 Verdadero/Falso con negativos difíciles) de 88,142 tripletas:

Segmento de Inferencia	Precisión (Acc)	Precision	Recall	F1-Score
in_KG (Todo conocido)	0.8525	0.8128	0.9159	0.8613
out_T (Cola desconocida)	0.7881	0.8028	0.7637	0.7828
out_H (Cabeza desconocida)	0.7694	0.78	0.7506	0.765
out_RT (Cola y Rel desconocidos)	0.6891	0.8327	0.4733	0.6035

Discusión

Diferencias entre InGram vs IKGE

Un enfoque alternativo para abordar el problema de la predicción inductiva en grafos de conocimiento es el propuesto por modelos como Inductive Knowledge Graph Embedding (IKGE), los cuales se apoyan en representaciones semánticas derivadas de texto. En este tipo de modelos, los embeddings de entidades y relaciones se obtienen a partir de la información textual asociada a ellas, como nombres, descripciones o atributos disponibles en recursos externos. Dichas representaciones textuales se transforman mediante modelos de lenguaje o técnicas de embedding semántico para producir vectores que posteriormente son utilizados en tareas de predicción de enlaces.

En contraste, InGram adopta un enfoque fundamentalmente estructural para el problema inductivo. En lugar de depender de descripciones textuales, el modelo construye representaciones a partir de la estructura del grafo de conocimiento. Para ello, primero se define un grafo de relaciones, donde cada nodo corresponde a un tipo de relación y las aristas representan afinidades entre relaciones calculadas a partir de patrones estructurales observados en el grafo. A partir de este grafo se generan representaciones ocultas de las relaciones, las cuales posteriormente se utilizan en el proceso de agregación de información para construir representaciones de entidades.

La representación de cada entidad se obtiene mediante la agregación de información proveniente de su vecindario en el grafo, considerando tanto las entidades conectadas como los tipos de relaciones que las vinculan. De esta manera, el modelo aprende a producir representaciones latentes utilizando únicamente información estructural local. Un aspecto clave del diseño de InGram es que el modelo no aprende embeddings específicos para entidades o relaciones individuales, sino que aprende los parámetros de una función de agregación capaz de generar representaciones para cualquier entidad o relación a partir de su contexto estructural. Esta característica permite que el modelo pueda generalizar a entidades no observadas durante el entrenamiento, lo cual es fundamental en escenarios inductivos.

Impacto de la estructura del grafo

Efecto de la profundidad L1, L2, L3

InGram

Los resultados obtenidos muestran un comportamiento consistente en el caso de la profundidad asociada a entidades. En los tres conjuntos de datos evaluados, la configuración con profundidad $L_e=2$ —correspondiente a la agregación de información proveniente de vecinos y vecinos de vecinos— se encuentra entre los mejores resultados reportados. En el conjunto NL-25, esta configuración alcanza el mejor desempeño en todas las métricas evaluadas, mostrando una mejora

notable respecto a profundidades menores o mayores. En los conjuntos WK-25 y FB-25, aunque la configuración $L_e=2$ no siempre corresponde estrictamente al valor máximo, su desempeño se mantiene muy cercano al mejor resultado observado, lo que sugiere que incorporar información estructural hasta el segundo nivel del vecindario es suficiente para capturar la mayor parte de las dependencias relevantes en el grafo.

Por otro lado, al incrementar la profundidad más allá de este nivel se observa una degradación clara en el desempeño, particularmente visible en NL-25, donde profundidades mayores provocan una disminución significativa en las métricas. Este comportamiento sugiere que una propagación excesiva de información puede introducir ruido estructural o diluir las señales locales más relevantes para la tarea de predicción de enlaces.

En contraste, la profundidad asociada a relaciones presenta un comportamiento menos uniforme entre conjuntos de datos. Mientras que en NL-25 el mejor resultado se obtiene con una profundidad mínima ($L_r=1$), en WK-25 el desempeño mejora gradualmente al aumentar la profundidad hasta $L_r=3$. En FB-25, por su parte, la mejor configuración corresponde a $L_r=2$, mientras que profundidades mayores vuelven a deteriorar el rendimiento. Estos resultados sugieren que la propagación de información entre relaciones depende en mayor medida de las características estructurales particulares de cada grafo de conocimiento.

En conjunto, estos hallazgos indican que la profundidad óptima del modelo no es necesariamente simétrica entre entidades y relaciones. Mientras que la agregación de información en entidades parece estabilizarse consistentemente en un vecindario de segundo orden, la profundidad óptima para relaciones varía entre conjuntos de datos, lo que sugiere que la profundidad óptima no es universal, depende del régimen estructural del grafo.

IKGE

Los resultados obtenidos en la implementación de IKGE también sugieren que utilizar un nivel de profundidad alto puede degradar el performance completo del modelo. Si bien nuestros resultados no permiten comparar los casos superior e inferior y afirmar con completa certeza si una degradación en la calidad puede suceder, sí sugieren que resultados comparativamente buenos en performance pueden obtenerse si se utiliza un k-hop menor que el utilizado durante el estudio original de 3, lo que ahorra en procesamiento computacional, almacenamiento y complejidad del entrenamiento.

De la misma manera, esta decisión nos lleva a recordar el régimen estructural del grafo que beneficia a un modelo como IKGE. Podemos afirmar de nuestros resultados que un grafo de baja densidad no permite concebir a IKGE como una opción predictiva eficiente, dada la pérdida que el grafo experimentará por el type matching estricto y pocos hechos adyacentes (facts) conectados por entidad.

Consideraciones para la Selección Adaptativa de profundidad

Motivación para selección adaptativa

Los resultados experimentales muestran que, a diferencia de la profundidad asociada al módulo de entidades, la profundidad óptima para la agregación de relaciones no presenta un comportamiento consistente entre los distintos conjuntos de datos analizados. Mientras que en algunos casos el mejor desempeño se obtiene con niveles de propagación relativamente bajos, en otros escenarios el modelo se beneficia de una mayor profundidad en el grafo de relaciones.

Este comportamiento sugiere que la utilidad de expandir el vecindario de relaciones depende fuertemente de las características estructurales del grafo de conocimiento, tales como la densidad relacional, los patrones de co-ocurrencia entre relaciones o la distribución de conectividad entre tipos de predicado.

A partir de esta observación surge la posibilidad de desarrollar un mecanismo de selección adaptativa de profundidad, basado en un análisis estructural previo del grafo de relaciones. Dicho análisis permitiría estimar, de forma aproximada, el nivel de profundidad más adecuado para la propagación de información entre relaciones antes del proceso de entrenamiento.

Actualmente, la forma más directa de identificar esta configuración consiste en realizar múltiples ejecuciones del modelo variando el número de capas, lo cual implica un costo computacional considerable. Un procedimiento de análisis estructural preliminar podría reducir significativamente este espacio de búsqueda, proporcionando indicadores que orienten la selección inicial de profundidad en el modelo y disminuyendo el costo experimental necesario para encontrar configuraciones eficientes.

Enfoque para selección adaptativa

La variabilidad observada en el comportamiento de la profundidad óptima para la agregación de relaciones sugiere que este parámetro depende de las características estructurales del grafo de relaciones asociado al conjunto de datos. Bajo esta perspectiva, la selección de profundidad puede formularse como un problema de inferencia basado en propiedades estructurales del grafo.

Sea $G_r = (R, E_r)$ el grafo de relaciones, donde R representa el conjunto de relaciones y E_r las conexiones estructurales entre ellas. El objetivo consiste en determinar una profundidad óptima de propagación para el módulo de relaciones del modelo, denotada como:

$$L_r^* \in \{1, 2, \dots, L_{max}\}$$

Donde L_{max} corresponde al máximo número de capas consideradas en el proceso de agregación estructural.

La selección adaptativa de profundidad puede plantearse como una función de las propiedades estructurales del grafo de relaciones:

$$L_r^* = g(S(G_r))$$

Con $S(G_r)$ un vector de propiedades estructurales, como densidad, grado promedio, diámetro o coeficiente de clustering.

Donde $g(\bullet)$ puede implementarse mediante reglas heurísticas, funciones de optimización o modelos predictivos. Bajo esta formulación, la elección de profundidad deja de tratarse como una búsqueda exhaustiva y se convierte en un problema de inferencia guiada por la estructura del grafo.

Algunas de estas propiedades pueden definirse formalmente de la siguiente manera. La densidad del grafo de relaciones puede expresarse como:

$$\delta(G_r) = \frac{2|E_r|}{|R|(|R| - 1)}$$

mientras que el grado promedio del grafo se define como:

$$\bar{k}(G_r) = \frac{1}{|R|} \sum_{r \in R} \deg(r)$$

Otra propiedad relevante es el diámetro del grafo, que corresponde a la mayor distancia geodésica entre pares de nodos:

$$D(G_r) = \max_{u, v \in R} d(u, v)$$

Estas métricas permiten caracterizar el nivel de conectividad y la extensión de la propagación de información dentro del grafo de relaciones.

Bajo esta formulación, la profundidad óptima puede estimarse mediante reglas heurísticas o funciones de decisión basadas en dichas propiedades estructurales. Por ejemplo, grafos con alta densidad relacional podrían requerir niveles de propagación más bajos, mientras que grafos más dispersos podrían beneficiarse de profundidades mayores que permitan capturar dependencias estructurales más lejanas.

Alternativamente, la profundidad puede seleccionarse en función del alcance estructural logrado tras múltiples pasos de propagación. Sea $N^L(r)$ el conjunto de relaciones alcanzables desde una relación r tras L pasos en el grafo de relaciones. Definimos entonces la cobertura promedio del grafo como:


$$\Gamma(L) = \frac{1}{|R|} \sum_{r \in R} \frac{|N^L(r)|}{|R|}$$

La profundidad puede seleccionarse como el menor valor de L que alcance un nivel deseado de cobertura estructural:

$$L_r^* = \min \{L : \Gamma(L) \geq \eta\}$$

Donde η representa un umbral de cobertura estructural predefinido.

Bajo este enfoque, la selección de profundidad deja de depender exclusivamente de exploración experimental y puede abordarse mediante análisis estructural previo del grafo de relaciones, reduciendo el espacio de búsqueda de hiperparámetros y el costo computacional asociado al entrenamiento del modelo.



Conclusión

En este trabajo se analizó el comportamiento de modelos inductivos de Knowledge Graph Embedding en escenarios de extrapolación donde aparecen entidades no observadas durante el entrenamiento. En particular, se evaluó el efecto de la profundidad de propagación estructural en el modelo InGram, así como su relación con el desempeño obtenido en tareas de predicción de enlaces.

Uno de los supuestos comunes en modelos basados en propagación estructural es que incrementar el número de capas o niveles de agregación conduce a representaciones más informativas. Sin embargo, los resultados obtenidos en los experimentos muestran que este supuesto no se cumple necesariamente en todos los casos. Tanto en InGram como en IKGE se observa de manera consistente que una profundidad de nivel 2 en el módulo de entidades produce el mejor desempeño, lo que sugiere que existe un punto óptimo de agregación para capturar información contextual relevante sin introducir ruido adicional proveniente de vecindarios estructurales más lejanos.

Por otra parte, el análisis del módulo de relaciones en InGram revela un comportamiento distinto. A diferencia de la propagación sobre entidades, la profundidad óptima para la agregación de relaciones no presenta un patrón uniforme entre los distintos conjuntos de datos analizados. Mientras que en algunos casos profundidades bajas producen mejores resultados, en otros escenarios el modelo se beneficia de niveles de propagación mayores. Este resultado sugiere que la profundidad asociada al grafo de relaciones no constituye un parámetro absoluto, sino que depende de las características estructurales particulares de cada conjunto de datos.

A partir de este hallazgo, se plantea la necesidad de desarrollar mecanismos que permitan estimar de forma adaptativa la profundidad adecuada para la propagación de información en el grafo de relaciones. En lugar de determinar este parámetro exclusivamente mediante exploración experimental, sería posible utilizar propiedades estructurales del grafo de relaciones como indicadores para orientar la selección inicial de profundidad en el modelo.

En conjunto, los resultados obtenidos muestran que, mientras que una profundidad moderada resulta suficiente para capturar información contextual a nivel de entidades, la propagación sobre relaciones presenta una mayor sensibilidad a la estructura del grafo. Esto abre una línea de investigación orientada a la selección adaptativa de profundidad basada en análisis estructural del grafo, con el objetivo de mejorar la eficiencia del proceso de entrenamiento y facilitar la configuración de modelos inductivos en grafos de conocimiento.

Referencias

- Bordes, A., Usunier, N., Garcia-Durán, A., Weston, J., & Yakhnenko, O. (2013). Translating embeddings for modeling multi-relational data. In *Advances in Neural Information Processing Systems* (Vol. 26).
<https://papers.nips.cc/paper/2013/hash/1cecc7a77928ca8133fa24680a88d2f9-Abstract.html>
- Chen, M., Zhang, W., Geng, Y., Xu, Z., Pan, J. Z., & Chen, H. (2023). Generalizing to unseen elements: A survey on knowledge extrapolation for knowledge graphs. *arXiv preprint arXiv:2302.01859*.
<https://arxiv.org/abs/2302.01859>
- Hamilton, W. L., Ying, R., & Leskovec, J. (2017). Inductive representation learning on large graphs. In *Advances in Neural Information Processing Systems* (Vol. 30).
<https://arxiv.org/abs/1706.02216>
- Hamaguchi, T., Oiwa, H., Shimbo, M., & Matsumoto, Y. (2017). Knowledge transfer for out-of-knowledge-base entities: A graph neural network approach. *arXiv preprint arXiv:1706.05674*.
<https://arxiv.org/abs/1706.05674>
- Lee, J., Chung, C., & Whang, J. J. (2020). INGRAM: Inductive knowledge graph embedding via relation graphs. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(03), 4054–4061.
<https://doi.org/10.1609/aaai.v34i03.5865>
- Nickel, M., Murphy, K., Tresp, V., & Gabrilovich, E. (2016). A review of relational machine learning for knowledge graphs. *Proceedings of the IEEE*, 104(1), 11–33.
<https://doi.org/10.1109/JPROC.2015.2483592>
- Oh, B., Seo, S., Hwang, J., Lee, D., Lee, K. (2022). Open-world knowledge graph completion for unseen entities and relations via attentive feature aggregation. In *Information Sciences*, 586, 468–484.
- Pennington, J., Socher, R., & Manning, C. (2014). GloVe: Global vectors for word representation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1532–1543.

- Schlichtkrull, M., Kipf, T. N., Bloem, P., van den Berg, R., Titov, I., & Welling, M. (2018). Modeling relational data with graph convolutional networks. In *The Semantic Web – ESWC 2018* (Lecture Notes in Computer Science, Vol. 10843, pp. 593–607). Springer. https://doi.org/10.1007/978-3-319-93417-4_38
- Teru, K. K., Denis, E., & Hamilton, W. L. (2020). Inductive relation prediction by subgraph reasoning. In *Proceedings of the 37th International Conference on Machine Learning* (pp. 9448–9457). PMLR. <https://arxiv.org/abs/1911.06962>
- Wang, Q., Mao, Z., Wang, B., & Guo, L. (2017). Knowledge graph embedding: A survey of approaches and applications. *IEEE Transactions on Knowledge and Data Engineering*, 29(12), 2724–2743. <https://doi.org/10.1109/TKDE.2017.2754499>
- Yamada, I., Asai, A., Sakuma, J., Shindo, H., Takeda, H., Takefuji, Y., & Matsumoto, Y. (2020). Wikipedia2Vec: An efficient toolkit for learning and visualizing the embeddings of words and entities from Wikipedia. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 23–30.