

Análisis de Grafos y Extrapolación de Conocimiento para identificar Relaciones No Explícitas de Información

Investigación

Presenta(n):

- Diego Andrés Bernal Díaz -- A01795975
- Silvia Xochitl Ibañez Vara -- A01795200
- José Adán Vega Pérez -- A01796093

Asesor: Raúl Valente Ramírez Velarde

Patrocinador(es):

Dr. Gerardo Jesús Camacho González

Dr. Eusebio Vargas Estrada

Grafos de Conocimiento


Los grafos de conocimiento representan información mediante estructuras relacionales que capturan entidades y las relaciones entre ellas. Se define un grafo de conocimiento como:

$$G = (E, R, T)$$

Formalmente, un grafo de conocimiento se compone de tripletas de la forma:

$$(h, r, t)$$

Donde h representa la entidad de origen (head), r la relación, t la entidad destino (tail)




Problema OOKB

Los Grafos de conocimiento se usan para representar información y relaciones entre entidades.

Sin embargo, en la práctica estos grafos cambian constantemente: aparecen nuevos productos, personas o conceptos.

El problema es que muchos modelos de inteligencia artificial solo funcionan si todas las entidades ya existían cuando el modelo fue entrenado.



¿Cómo puede un modelo entender algo que nunca vio?

Imaginemos...


Que un modelo que aprendió sobre muchos animales, pero nunca vio un panda.

El modelo sí sabe que un panda:

- vive en zonas boscosas Asiáticas
- come bambú
- es un mamífero

entonces puede inferir su lugar en el conocimiento existente.

Los modelos inductivos usan el contexto para entender entidades nuevas



Modelos que entienden entidades nuevas usando su contexto en el grafo

Existen modelos diseñados para este problema:

- TransE: clasificador simple de tripletas
- OOKB: genera representaciones usando agregaciones de vecindario de un grafo auxiliar
- RGCN: determina tripletas basado en redes convolucionales de grafos

En este trabajo analizamos dos enfoques principales:

- IKGE: genera representaciones usando modelos preentrenados
- InGram: aprende patrones entre entidades y relaciones a partir de la estructura de información.

¿Cuánto contexto estructural necesita realmente el modelo?


Ambos intentan entender entidades nuevas usando su contexto en el grafo, pero la diferencia se encuentra al contestar la siguiente pregunta:

Poco contexto $\Rightarrow$ falta de información

Demasiado $\Rightarrow$ Ruido

Metodología

Evaluamos cómo cambia el desempeño del modelo cuando aumentamos el nivel de contexto que el modelo observa.






Modelos que entienden entidades nuevas usando su contexto en el grafo

Característica	NL-25 (NELL)	WK-25 (WordNet)	FB-25 (Freebase)
Origen	Extracción automática desde texto web	Base léxica curada manualmente	Base enciclopédica estructurada
Tipo de grafo	Semántico abierto	Jerárquico taxonómico	Enciclopédico heterogéneo
Naturaleza de relaciones	Amplias y variadas (locatedIn, worksFor, presidentOf)	Principalmente jerárquicas (hypernym, hyponym)	Mixtas (bornIn, directedBy, industry, currency)
Regularidad estructural	Media-baja	Alta	Media
Profundidad típica de caminos	Corta a media	Larga y jerárquica	Variable
Densidad relacional	Variable (puede ser ruidosa)	Alta regularidad por categoría	Moderada
Nivel de ruido	Medio-alto (extracción automática)	Bajo (curado manualmente)	Bajo-medio
Riesgo de sobre-propagación	Alto si profundidad grande	Moderado	Alto en propagación excesiva
Comportamiento esperado con mayor profundidad	Puede degradarse por mezcla semántica	Puede beneficiarse hasta profundidad intermedia	Tiende a degradarse si se excede profundidad
Implicación para InGram	La propagación profunda puede amplificar ruido semántico debido a la extracción automática; una profundidad moderada suele ser suficiente para capturar señales útiles	La estructura jerárquica favorece la propagación estructural, permitiendo que profundidades intermedias capturen relaciones taxonómicas	La diversidad relacional permite capturar contexto estructural amplio, pero profundidades excesivas pueden mezclar señales heterogéneas
Implicación para IKGE	Puede verse afectado por ruido en vecinos debido a extracción automática; la calidad del subgrafo local es crítica para generar embeddings fiables	La estructura jerárquica y las relaciones consistentes favorecen la generación de embeddings inductivos a partir de vecinos	El subgrafo local suele ser informativo, pero la heterogeneidad de relaciones puede introducir señales mixtas en la generación de embeddings

L2 mejor Resultado InGgram en Entidades

El experimento sugiere que L2 puede ser una profundidad óptima. El desempeño depende de la estructura del grafo.

- NL-25: El mejor desempeño ocurre en profundidad 2, donde el MRR aumenta de 0.159 a 0.255 y Hits@10 de 0.306 a 0.371, lo que indica que considerar vecinos de segundo orden mejora significativamente las predicciones.
- WK-25: El rendimiento mejora gradualmente al aumentar la profundidad. El MRR pasa de 0.105 a 0.117 y Hits@10 de 0.172 a 0.211, sugiriendo que un mayor contexto estructural beneficia al modelo.
- FB-25: El impacto de la profundidad es más moderado. El MRR solo aumenta de 0.088 a 0.101 y Hits@10 de 0.176 a 0.225, lo que sugiere que la estructura del grafo aporta menos información adicional al aumentar la profundidad.



Resultados InGgram en Relaciones

Una mayor profundidad en la propagación de relaciones no mejora el desempeño, introduce ruido.

- NL-25: El mejor desempeño ocurre en profundidad 1. El MRR disminuye de 0.263 a 0.220 cuando se incrementa la profundidad, lo que sugiere que propagar información relacional más allá del primer nivel introduce ruido estructural.
- WK-25: El rendimiento también es mayor en profundidad 3 (MRR = 0.263, Hits@10 = 0.409). Al aumentar la profundidad a 2 y 3, el desempeño disminuye (MRR baja a 0.247 y 0.220), indicando que la información relacional relevante se encuentra principalmente en el contexto inmediato.
- FB-25: El impacto de la profundidad es más moderado, pero es mejor en 2, sigue observándose una ligera disminución en niveles mayores (MRR de 0.185 a 0.167). Esto sugiere que incrementar la propagación relacional no aporta información adicional significativa en este grafo.

NL-25, L_{other} = 2




Depth	MRR	Hits@10	Hits@1
1	0.159	0.306	0.075
2	0.255	0.371	0.189
3	0.111	0.188	0.069
4	0.043	0.082	0.018
1	0.263	0.409	0.185
2	0.247	0.353	0.189
3	0.220	0.326	0.167
4	0.138	0.271	0.081

WK-25; L_{other} = 2

Depth	MRR	Hits@10	Hits@1
1	0.105	0.172	0.064
2	0.109	0.210	0.055
3	0.112	0.211	0.060
1	0.117	0.211	0.066
2	0.116	0.200	0.078
3	0.130	0.210	0.087

FN-25; L_{other} = 2

Depth	MRR	Hits@10	Hits@1
1	0.088	0.176	0.040
2	0.100	0.222	0.041
3	0.101	0.225	0.040
1	0.097	0.222	0.034
2	0.112	0.242	0.048
3	0.084	0.184	0.032



No existe una profundidad estructural universalmente óptima en modelos inductivos de grafos de conocimiento

Hallazgo

La profundidad óptima depende del tipo de propagación estructural.

Aumentar la profundidad en relaciones no mejora el desempeño.

El efecto de la profundidad depende de la estructura del grafo.

Evidencia

En entidades, el mejor desempeño aparece en L2 (ej. NL-25: **MRR = 0.255**).

En relaciones, el mejor resultado aparece en L1 y disminuye al aumentar la profundidad (ej. WK-25: MRR 0.263 $\rightarrow$ 0.220).

Diferentes datasets muestran comportamientos distintos (NL-25, WK-25 y FN-25).

Resultados IKGE

IKGE funciona bien para generalizar a entidades nuevas, pero presenta limitaciones en la predicción de relaciones.

Predicción

Head Prediction

Tail Prediction

Tail + Head OOKB

Relation Prediction

Evidencia

Desempeño sólido, aunque por debajo del objetivo (0.39). Podría mejorar con más entrenamiento.

Buen desempeño en predicción de cola cuando hay información textual disponible.

El modelo logra generalizar a entidades no vistas, mostrando su capacidad inductiva.

Desempeño muy bajo debido a un problema en el entrenamiento del modelo reportado en el paper.

Grupo de Evaluación del Paper	Patrones O/X Evaluados	N° Tripletas	MRR Obtenido	Mean Rank	Objetivo MRR (FB20k+)
Group 1 - Head Pred.	O-O-X, O-X-X, O-X-O	13,105	0.3064	552.8	0.39
Group 2 - Tail Pred.	X-O-O, X-X-O, O-X-O	20,272	0.3771	165.7	0.4
Group 3 - Head+Tail OOK	O-O-X (H), X-O-O (T)	26,085	0.4053	49	0.42
Group 4 - Relation Pred. notación del paper original:	O-O-X, X-O-O, X-O-X	26,095	0.0396	413.1	0.36

Selección Adaptativa de Profundidad

Evidencia experimental:

- La profundidad óptima de propagación no es constante entre datasets.
- En entidades, una profundidad intermedia (L2) suele ofrecer mejores resultados.
- En relaciones, el desempeño varía según la estructura del grafo.
- Profundidades mayores pueden introducir ruido estructural.

Los modelos actuales utilizan una profundidad fija de propagación, definida empíricamente durante el entrenamiento.

Propuesta conceptual:

Que el modelo determine dinámicamente el nivel adecuado de propagación a partir de propiedades estructurales del grafo.

Implicación:

Modelos inductivos capaces de ajustar el contexto estructural de forma dinámica, mejorando la robustez del aprendizaje en grafos de conocimiento.

Conclusión

1. La profundidad de **propagación estructural influye** significativamente en el desempeño de los modelos inductivos en grafos de conocimiento.
2. **No existe una profundidad universalmente óptima**; el nivel adecuado depende de la estructura del grafo y del tipo de predicción.
3. En la predicción de entidades, **profundidades intermedias pueden capturar contexto útil sin incorporar ruido**. En la predicción de relaciones, aumentar la profundidad puede degradar el desempeño debido a la propagación de información irrelevante.
4. Los resultados sugieren que **propiedades estructurales del grafo podrían utilizarse para guiar la selección de profundidad**, abriendo la puerta a modelos con selección adaptativa de propagación estructural.

Trabajo Futuro

- **Selección adaptativa de profundidad estructural**

Desarrollar métodos que permitan ajustar dinámicamente el nivel de propagación en función de las características del grafo.

- **Análisis estructural de grafos de conocimiento**

Investigar qué propiedades estructurales del grafo pueden servir como indicadores para estimar la profundidad óptima.

- **Evaluación en grafos de mayor escala**

Extender los experimentos a grafos de conocimiento más grandes y en diferentes dominios para validar la generalización de los resultados.

- **Comparación con otros modelos inductivos**

Analizar el comportamiento de arquitecturas adicionales para comprender mejor las condiciones en las que cada enfoque es más efectivo.

Q&A