



Tecnológico de Monterrey

Maestría en Inteligencia Artificial Aplicada

Análisis de Grafos y Extrapelación de Conocimiento para
identificar Relaciones No Explícitas de información

Investigación

Profesor Dr. Gerardo Jesús Camacho González

Profesor Dr. Eusebio Vargas Estrada

Equipo 32

Diego Andrés Bernal Díaz

A01795975

Silvia Xochitl Ibañez Vara

A01795200

José Adán Vega Pérez

A01796093

Contenido

Introducción.....	4
Antecedentes.....	6
Knowledge Graph Embeddings.....	6
Redes neuronales sobre grafos	7
Modelos inductivos para grafos de conocimiento.....	7
Extrapolación de conocimiento en grafos	8
Planteamiento del problema	8
Metodología propuesta.....	10
Modelo inductivo basado en vecindario: IKGE	10
Modelo basado en propagación estructural: InGram.....	10
Propagación estructural	11
Profundidad de propagación en el grafo.....	12
Configuración Experimental.....	12
InGram	12
Escenario experimental y selección de datasets	12
Arquitectura del modelo y parámetros explorados.....	13
Reimplementación y análisis de reproducibilidad de IKGE	13
Escenario experimental y selección de datasets	14
Arquitectura del modelo y parámetros explorados.....	15
Ajustes necesarios para convergencia de model modelo.....	15
Brechas de reproductividad identificadas.....	17
Métricas de evaluación.....	18
Infraestructura computacional	19
Características estructurales de los grafos.....	19
Resultados.....	20
Experimento InGram.....	20
Experimento IKGE	21
Discusión	22
Comparación entre InGram vs IKGE.....	22
Impacto de la estructura del grafo.....	23
Efecto de la profundidad L1, L2, L3.....	23
InGram.....	23
IKGE.....	24
Selección Adaptativa de profundidad de propagación	24
Motivación para selección adaptativa.....	24
Enfoque para selección adaptativa	25

<i>Conclusión.....</i>	<i>27</i>
<i>Trabajo futuro</i>	<i>28</i>
<i>Referencias</i>	<i>30</i>

Introducción

Los grafos de conocimiento se han consolidado como una herramienta fundamental para representar información relacional en diversos dominios, incluyendo sistemas de recomendación, recuperación de información, análisis semántico y procesamiento de lenguaje natural. En estos sistemas, el conocimiento se modela comúnmente mediante tripletas de la forma (h, r, t), donde h representa la entidad origen (head), r la relación y t la entidad destino (tail). Esta representación permite capturar relaciones complejas entre entidades y facilita tareas de inferencia como la predicción de enlaces dentro del grafo.

En los últimos años, los métodos de Knowledge Graph Embedding (KGE) han sido ampliamente utilizados para aprender representaciones vectoriales continuas de entidades y relaciones, permitiendo aplicar técnicas de aprendizaje automático sobre estructuras relacionales (Bordes et al., 2013; Wang et al., 2017). Estos modelos proyectan entidades y relaciones en un espacio latente donde las relaciones semánticas pueden modelarse mediante funciones de puntuación sobre tripletas. Sin embargo, la mayoría de los enfoques tradicionales asumen que el conjunto de entidades y relaciones permanece fijo durante el entrenamiento, lo cual limita su capacidad para adaptarse a grafos de conocimiento dinámicos donde nuevos elementos pueden aparecer con el tiempo (Nickel et al., 2016).

Para abordar esta limitación, investigaciones recientes han explorado el problema de la extrapolación de conocimiento en grafos, cuyo objetivo es permitir que los modelos generalicen hacia entidades previamente no observadas durante el entrenamiento (Chen et al., 2023). Este escenario se conoce comúnmente como Out-of-Knowledge-Base (OOKB) y plantea el desafío de generar representaciones para nuevas entidades a partir de la estructura del grafo disponible. A diferencia de los enfoques transductivos tradicionales, los métodos inductivos buscan derivar embeddings a partir del contexto estructural de las entidades dentro del grafo.

Entre los enfoques propuestos para abordar este problema, Inductive Knowledge Graph Embedding (IKGE) genera representaciones para entidades no vistas a partir de su vecindario estructural, permitiendo extender el modelo a nuevas entidades sin necesidad de reentrenamiento completo (Oh et al., 2022). Mientras que, InGram introduce un mecanismo inductivo basado en propagación estructural y grafos de relaciones que permite reconstruir representaciones tanto para entidades como para relaciones a partir de la conectividad del grafo (Lee et al., 2023). A diferencia de los modelos que dependen únicamente del subgrafo local, InGram incorpora mecanismos de propagación estructural que permiten capturar contexto relacional más amplio.

En este trabajo se realiza un análisis comparativo entre IKGE e InGram en escenarios de extrapolación de conocimiento donde emergen entidades no vistas. Los experimentos se realizan sobre tres datasets derivados de grafos de conocimiento con características estructurales distintas, lo que permite analizar cómo la estructura del grafo influye en la capacidad de generalización de los modelos inductivos.

Adicionalmente, se analiza el impacto de la profundidad de propagación estructural en InGram, evaluando configuraciones de profundidad L1, L2 y L3 tanto en el módulo de entidades como en el módulo de relaciones del modelo. Este análisis permite estudiar cómo diferentes niveles de contexto estructural afectan el desempeño del modelo en distintos tipos de grafos de conocimiento.

Este trabajo aborda los siguientes aspectos:

1. Un análisis comparativo entre IKGE e InGram en escenarios de extrapolación de conocimiento con entidades no vistas.
2. Un estudio empírico del efecto de la profundidad de propagación estructural en InGram, evaluando configuraciones L1, L2 y L3 en los módulos de entidades y relaciones.
3. Evidencia experimental de que el comportamiento de la profundidad óptima depende de las características estructurales del grafo de conocimiento.
4. Un análisis interpretativo que relaciona el desempeño de los modelos con la naturaleza estructural de distintos grafos de conocimiento.
5. Una discusión conceptual sobre los elementos necesarios para una futura selección adaptativa de profundidad en modelos inductivos de grafos de conocimiento.

A partir de este análisis, se desprenden las siguientes contribuciones:

1. Análisis experimental del impacto de la profundidad de propagación estructural en modelos inductivos de grafos de conocimiento, específicamente InGram e IKGE.
2. Reproducción experimental del modelo IKGE y la identificación de limitaciones de reproducibilidad en su implementación original.
3. Observación empírica de que la profundidad óptima para agregación de entidades tiende a estabilizarse en dos saltos estructurales, mientras que la profundidad asociada a relaciones depende de las características estructurales del grafo.

Antecedentes

Knowledge Graph Embeddings

Los grafos de conocimiento representan información mediante estructuras relacionales que capturan entidades y las relaciones entre ellas. Se define un grafo de conocimiento como

$$G = (E, R, T)$$

Formalmente, un grafo de conocimiento se compone de tripletas de la forma:

$$(h, r, t)$$

Donde h representa la entidad de origen (head), r la relación, t la entidad destino (tail)

Este tipo de representación permite modelar relaciones complejas entre entidades y construye la base para tareas de inferencia como la predicción de enlaces.

Con el objetivo de aplicar métodos de aprendizaje automático sobre grafos de conocimiento, se han desarrollado técnicas de Knowledge Graph Embedding (KGE), cuyo propósito es aprender representaciones vectoriales continuas de entidades y relaciones en un espacio latente φ_x , (Wang et al., 2017). En este espacio, las relaciones semánticas entre entidades pueden modelarse mediante funciones score:

$$f(h, r, t)$$

que evalúan la plausibilidad de las tripletas.

Uno de los enfoques más influyentes en esta línea es TransE, propuesto por Bordes et al. (2013), que modela las relaciones como operaciones de traslación en el espacio vectorial.

$$f(h, r, t) = -|\mathbf{e}_h + \mathbf{r} - \mathbf{e}_t|$$

La idea es que una tripleta válida cumple aproximadamente:

$$\mathbf{e}_h - \mathbf{r} \approx \mathbf{e}_t$$

En este modelo, una relación $\mathbf{r}$ se interpreta como una transformación que conecta la representación de la entidad origen con la entidad destino en el espacio de embeddings. Este enfoque dio origen a una amplia familia de modelos traslacionales que buscan capturar diferentes tipos de patrones relacionales en grafos de conocimiento.

A pesar de su éxito en tareas de predicción de enlaces, estos modelos presentan una limitación importante: generalmente operan bajo un escenario transductivo, en el cual el conjunto de entidades y relaciones se asume fijo durante el entrenamiento. Como consecuencia, cuando aparecen nuevas entidades en el grafo, el modelo no puede generar representaciones adecuadas sin realizar un reentrenamiento completo (Nickel et al., 2016)

Redes neuronales sobre grafos

Con el objetivo de incorporar información estructural del grafo de manera más explícita, diversas investigaciones han explorado el uso de Graph Neural Networks (GNN) para el aprendizaje de representaciones en grafos de conocimiento. Las GNN permiten propagar información entre nodos vecinos mediante mecanismos de agregación que capturan dependencias estructurales en el grafo.

Dentro de este enfoque, Relational Graph Convolutional Networks (RGCN) introducen una extensión de las redes convolucionales sobre grafos que considera explícitamente la naturaleza multirrelacional de los grafos de conocimiento (Schlichtkrull et al., 2018). En este modelo, cada relación del grafo se asocia con una transformación específica que permite modelar distintos tipos de interacciones entre entidades.

El uso de GNN ha permitido mejorar el modelado de dependencias estructurales en grafos de conocimiento. Sin embargo, muchos de estos modelos continúan operando bajo supuestos transductivos y dependen de representaciones previamente aprendidas para cada entidad, lo cual limita su capacidad de generalizar a entidades que no han sido observadas durante el entrenamiento.

Modelos inductivos para grafos de conocimiento

Para superar las limitaciones de los enfoques transductivos, investigaciones recientes han propuesto modelos inductivos capaces de generar representaciones para entidades previamente no observadas. En estos enfoques, los embeddings no se asocian directamente a identificadores específicos de entidades, sino que se generan a partir del contexto estructural del grafo.

Uno de los enfoques en esta línea es Inductive Knowledge Graph Embedding (IKGE), propuesto por Oh et al. (2022). Este método genera embeddings para entidades no vistas utilizando información proveniente de su vecindario estructural dentro del grafo. De esta forma, las representaciones pueden derivarse a partir de las relaciones y entidades conectadas, permitiendo extender el modelo a nuevas entidades sin necesidad de reentrenamiento completo.

Por otra parte, el modelo InGram introduce un enfoque inductivo basado en propagación estructural que busca capturar patrones relacionales de mayor alcance (Lee et al., 2023). A diferencia de los métodos que dependen únicamente del subgrafo local de una entidad, InGram

incorpora un grafo de relaciones que permite modelar interacciones entre diferentes tipos de relaciones presentes en el grafo de conocimiento. Mediante este mecanismo, el modelo puede reconstruir representaciones tanto para entidades como para relaciones a partir de la estructura del grafo.

Este tipo de enfoque permite capturar contextos estructurales más amplios y ofrece una mayor capacidad de generalización en escenarios donde aparecen nuevas entidades.

Extrapolación de conocimiento en grafos

El problema de generar representaciones para elementos previamente no observados en un grafo de conocimiento se conoce comúnmente como extrapolación de conocimiento. Este escenario surge cuando el grafo evoluciona con el tiempo y aparecen nuevas entidades o relaciones que no estaban presentes durante el entrenamiento del modelo.

Este problema ha sido ampliamente estudiado en la literatura reciente y suele denominarse Out-of-Knowledge-Base (OOKB). En este contexto, el objetivo consiste en permitir que los modelos aprendan mecanismos de representación capaces de generalizar más allá de las entidades y relaciones observadas inicialmente (Chen et al., 2023).

Diversos enfoques han sido propuestos para abordar este desafío, incluyendo métodos basados en subgrafos, mecanismos de razonamiento estructural y modelos inductivos capaces de generar embeddings dinámicamente a partir del contexto del grafo. Estas investigaciones reflejan una tendencia creciente hacia modelos que priorizan la capacidad de generalización estructural en grafos de conocimiento dinámicos.

En este contexto, el estudio comparativo de distintos enfoques inductivos y el análisis de los mecanismos que influyen en su capacidad de generalización constituyen un área activa de investigación en el campo de los grafos de conocimiento.

Planteamiento del problema

Los grafos de conocimiento representan información mediante estructuras relacionales formadas por entidades y las relaciones entre ellas. Formalmente, un grafo de conocimiento se define como:

$$G = (E, R, T)$$

Donde:

- $e \in E$, el conjunto de entidades
- $r \in R$, es el conjunto de relaciones
- $t \in T$, es el conjunto de tripletas

Cada tripleta tiene la forma:

$$(h, r, t)$$

Donde $h, t \in E$, representan la entidad origen (*head*) y la entidad destino (*tail*), mientras que $r \in R$, corresponde al tipo de relación que conecta ambas entidades.

En los métodos de Knowledge Graph Embedding, el objetivo consiste en aprender representaciones vectoriales continuas de entidades y relaciones en un espacio latente de dimensión d . Estas representaciones se obtienen mediante funciones de embedding que asignan a cada entidad y relación un vector en el espacio:

$$\varphi_E: E \rightarrow \mathbb{R}^d$$

$$\varphi_R: R \rightarrow \mathbb{R}^d$$

De esta manera, cada entidad $e \in E$ se representa mediante un vector $e = \varphi_E(e)$, mientras que cada relación $r \in R$ $r = \varphi_R(r)$.

Estas representaciones permiten evaluar la plausibilidad de una tripleta mediante una función score:

$$f(h, r, t) = f(\varphi_E(h), \varphi_R(r), \varphi_E(t))$$

donde valores más altos indican una mayor probabilidad de que la tripleta corresponda a una relación válida en el grafo de conocimiento.

En los enfoques tradicionales de embeddings para grafos de conocimiento, las representaciones vectoriales se aprenden directamente para cada entidad presente en el conjunto de entrenamiento. Este supuesto implica que el conjunto de entidades es fijo durante el proceso de aprendizaje. Como consecuencia, cuando aparecen nuevas entidades que no fueron observadas durante el entrenamiento, el modelo no puede generar representaciones adecuadas para ellas sin realizar un nuevo proceso de entrenamiento.

Este escenario da lugar al problema conocido como Out-of-Knowledge-Base (OOKB), en el cual el modelo debe ser capaz de generar representaciones para entidades previamente no observadas utilizando únicamente la información estructural disponible en el grafo de conocimiento.

Para abordar este desafío, los modelos inductivos buscan aprender funciones de representación capaces de generar embeddings para nuevas entidades a partir de su contexto estructural dentro del grafo. En lugar de asociar directamente un vector a cada entidad, estos enfoques utilizan la estructura del grafo y las relaciones entre entidades para inferir representaciones dinámicamente.

En este trabajo se estudia el problema de extrapolación de conocimiento en grafos donde aparecen **nuevas entidades**, analizando el comportamiento de distintos enfoques inductivos capaces de generar representaciones para entidades no vistas a partir de la estructura del grafo de conocimiento.

Metodología propuesta

En este trabajo se estudia el problema de extrapolación de conocimiento en grafos donde aparecen entidades que no fueron observadas durante el entrenamiento. Formalmente, el conjunto de entidades del grafo puede dividirse en dos subconjuntos:

$$E = E_{train} \cup E_{new}$$

Donde E_{train} corresponde a las entidades observadas durante el entrenamiento y E_{new} representa las entidades que aparecen únicamente en los conjuntos de validación o prueba.

El objetivo consiste en evaluar la capacidad de distintos modelos para generar embeddings para entidades pertenecientes a E_{new} utilizando únicamente el grafo y la información relacional disponible.

Modelo inductivo basado en vecindario: IKGE

Los modelos de Inductive Knowledge Graph Embedding (IKGE) generan representaciones para entidades no vistas utilizando la información estructural de su vecindario en el grafo.

En este enfoque, el embedding de una entidad se obtiene mediante una función que depende del contexto relacional de la entidad dentro del grafo:

$$e_i = \varphi(E_i, N(i))$$

donde $N(i)$ representa el conjunto de entidades y relaciones conectadas con la entidad i . De esta manera, el embedding no depende directamente de un identificador específico de entidad, sino de las interacciones estructurales que dicha entidad mantiene en el grafo de conocimiento. Este mecanismo permite generar representaciones para entidades previamente no observadas, siempre que exista información relacional disponible en su vecindario.

Modelo basado en propagación estructural: InGram

El modelo InGram propone un enfoque inductivo basado en la propagación estructural de información a través del grafo de conocimiento. A diferencia de métodos que utilizan únicamente el vecindario local de cada entidad, InGram incorpora dos niveles de representación estructural:

1. Propagación entre entidades
2. Propagación entre relaciones

Para capturar dependencias entre relaciones, el modelo introduce un grafo de relaciones definido como:

$$G = (R, E_r)$$

donde los nodos corresponden a relaciones presentes en el grafo de conocimiento y las aristas representan interacciones estructurales entre relaciones observadas en las tripletas

Este mecanismo permite modelar patrones relacionales más complejos y facilita la propagación de información semántica entre diferentes tipos de relaciones.

El modelo aprende representaciones tanto para entidades como para relaciones mediante procesos iterativos de propagación estructural.

Propagación estructural

Durante el proceso de aprendizaje, las representaciones se actualizan mediante iteraciones de propagación que agregan información proveniente de los vecinos estructurales.

Para las entidades, las representaciones se actualizan utilizando información de las entidades conectadas a través de las relaciones del grafo:

$$e_i^{(l+1)} = \sigma \left(\sum_{(i,r,j) \in T} W_r e^{(l)} \right)$$

Donde:

- l es la propagación
- W_r es una transformación asociada a la relación r
- σ es una función de activación no lineal

De manera análoga, las representaciones de las relaciones se actualizan mediante agregación sobre el grafo de relaciones:

$$r_i^{(l+1)} = \sigma \left(\sum_{r' \in N(r)} W r'^{(l)} \right)$$

Donde $N(r)$ representa el conjunto de relaciones vecinas en el grafo de relaciones.

Profundidad de propagación en el grafo

La propagación estructural en InGram puede aplicarse durante múltiples iteraciones. La profundidad de propagación determina cuántas capas de agregación estructural se utilizan para actualizar las representaciones.

En este trabajo se evalúan configuraciones con diferentes niveles de profundidad:

$$L \in \{1, 2, 3\}$$

Donde L indica el número de iteraciones de propagación estructural aplicadas durante el aprendizaje del modelo.

El objetivo de este análisis consiste en analizar cómo la profundidad de propagación influye en la capacidad del modelo para capturar dependencias estructurales y generar representaciones adecuadas para entidades no vistas.

Configuración Experimental

InGram

En esta sección se describe la configuración experimental utilizada para evaluar el modelo InGram bajo diferentes configuraciones de profundidad en la agregación de información estructural. Para ello se realizaron múltiples ejecuciones del modelo variando el número de capas asociadas a entidades y relaciones, mientras que el resto de los hiperparámetros se mantuvo constante de acuerdo con la implementación original. El desempeño del modelo se evaluó mediante tareas de predicción de enlaces.

Escenario experimental y selección de datasets

Los experimentos se realizaron utilizando los conjuntos de datos proporcionados en el repositorio oficial de InGram, específicamente las variantes NL-25, WK-25 y FB-25, derivadas de los grafos de conocimiento NELL, WordNet y Freebase, respectivamente. Estos conjuntos fueron diseñados para evaluar modelos en escenarios inductivos de grafos de conocimiento.

En estas configuraciones, aproximadamente el 25% de las entidades del grafo aparecen únicamente en los conjuntos de validación y prueba, mientras que el modelo se entrena únicamente con las entidades presentes en el conjunto de entrenamiento. Este tipo de partición permite evaluar la

capacidad de los modelos para generar representaciones para entidades previamente no observadas, utilizando únicamente la información estructural disponible en el grafo.

La división de los datos en conjuntos de entrenamiento, validación y prueba se utilizó exactamente como se define en la implementación original de InGram, sin realizar modificaciones adicionales. Esto permite mantener la comparabilidad con los resultados reportados en trabajos previos que utilizan estos mismos conjuntos de evaluación.

Arquitectura del modelo y parámetros explorados

Los experimentos se realizaron utilizando la arquitectura original del modelo InGram, sin modificaciones estructurales. El objetivo de la experimentación fue analizar el efecto de la profundidad de propagación estructural en los módulos de entidades y relaciones del modelo.

Para ello se realizaron conjuntos de experimentos independientes en los que se varió el número de capas asociadas a la profundidad de agregación en entidades y relaciones. En cada experimento se modificó únicamente uno de estos parámetros, mientras que el otro se mantuvo fijo en su valor por defecto. De esta manera, al evaluar la profundidad de entidades se mantuvo constante la profundidad de relaciones, y viceversa, lo que permite aislar el efecto de cada componente del modelo sobre el desempeño en la tarea de predicción de enlaces.

El resto de los hiperparámetros del modelo, incluyendo la dimensionalidad de los embeddings, la tasa de aprendizaje, el número de ejemplos negativos y los parámetros de entrenamiento, se mantuvieron en los valores definidos por la implementación original del repositorio de InGram. Esto permite asegurar que las diferencias observadas en los resultados se deben únicamente a las variaciones en la profundidad del modelo.

Reimplementación y análisis de reproducibilidad de IKGE

Debido a la ausencia de una implementación oficial publicada por los autores del estudio original, se desarrolló una implementación propia del modelo siguiendo la arquitectura y los parámetros estructurales descritos en el artículo. El modelo IKGE corresponde a una arquitectura inductiva de mundo abierto (open-world), diseñada para inferir representaciones de entidades que no han sido observadas durante el entrenamiento.

A diferencia de los enfoques tradicionales de knowledge graph embedding, que aprenden un vector estático para cada entidad presente en el conjunto de entrenamiento, IKGE construye representaciones de entidades a partir de información semántica y estructural disponible. En particular, el modelo utiliza embeddings pre-entrenados para inicializar representaciones semánticas, extrae características a partir de descripciones textuales y metadatos asociados a las entidades (como nombres y restricciones de tipo), y posteriormente enriquece estas

representaciones mediante una red neuronal convolucional de grafos (GCN) basada en mecanismos de atención. Este proceso permite incorporar información contextual proveniente del vecindario estructural del grafo a múltiples saltos (K-hops).

Durante el proceso de implementación se identificaron algunos desafíos relacionados con la reproducibilidad del método descrito en el artículo original, particularmente en lo referente a la especificación detallada del procedimiento de entrenamiento y evaluación del modelo. Como resultado, fue necesario definir explícitamente ciertos componentes de la arquitectura y del proceso de optimización que no estaban completamente especificados en la descripción original.

A partir de esta implementación se llevaron a cabo diversos experimentos exploratorios, en los cuales se evaluaron distintas configuraciones del modelo, incluyendo variaciones en la función de pérdida utilizada, diferentes modelos de embeddings pre-entrenados y una modificación estructural en el mecanismo de type matching originalmente propuesto. Estas configuraciones permitieron analizar el comportamiento del modelo bajo distintas condiciones y evaluar su desempeño en grafos de conocimiento con características estructurales diversas.

Escenario experimental y selección de datasets

Para evaluar el comportamiento del modelo IKGE se recompilaron versiones propias de los datasets DBpedia50k+ y FB20k+, utilizando como punto de partida las versiones públicas disponibles en línea. El objetivo de esta recompilación fue reproducir, en la medida de lo posible, las condiciones experimentales reportadas en el estudio original y establecer un punto de comparación confiable entre nuestra implementación y los resultados publicados.

A partir de las fuentes disponibles se construyeron datasets con tamaños y características lo más cercanas posibles a los reportados en la publicación original. Como primer paso se seleccionó DBpedia50k+ debido a su menor tamaño relativo, lo que permite realizar ciclos de entrenamiento más cortos y experimentación iterativa más rápida en comparación con datasets de mayor escala.

Durante las primeras ejecuciones se observó que los resultados obtenidos diferían significativamente de los reportados en el artículo original. Esto motivó un análisis detallado de los componentes del modelo, particularmente en relación con el uso de embeddings preentrenados. En la implementación inicial se utilizó el modelo GloVe (Pennington et al., 2014), sin embargo, se encontró que la cobertura del vocabulario del grafo alcanzaba únicamente aproximadamente 27% de las entidades presentes en el dataset.

Con el fin de mejorar esta cobertura se adoptó el modelo Wikipedia2Vec (Yamada et al., 2020), junto con un proceso de lematización del vocabulario del grafo, estrategias también utilizadas en el estudio original. Estas modificaciones permitieron aumentar la cobertura semántica del modelo de embeddings hasta aproximadamente 85% del vocabulario del grafo.

No obstante, incluso después de estas modificaciones los resultados obtenidos continuaron siendo significativamente inferiores a los reportados en el artículo original. A partir de este punto, y siguiendo un enfoque iterativo inspirado en metodologías de ingeniería de aprendizaje automático como CRISP-ML, se realizó un análisis más profundo de las características estructurales del dataset utilizado.

Este análisis condujo a una segunda hipótesis: el modelo IKGE requiere grafos de conocimiento con una densidad relacional relativamente alta, es decir, un número suficiente de relaciones por entidad que permita construir subgrafos estructurales informativos durante el proceso de propagación.

La versión recompilada de DBpedia50k+ utilizada en este trabajo presentaba aproximadamente 2.7 relaciones por entidad, lo cual resultó insuficiente para el correcto funcionamiento del modelo. Ante la imposibilidad de recuperar exactamente las fuentes de datos utilizadas en la publicación original, se procedió a construir una versión del dataset FB20k+ siguiendo las mismas premisas estructurales reportadas en el artículo.

El dataset resultante presenta una densidad promedio de aproximadamente 67 relaciones por entidad, condición bajo la cual el modelo logró alcanzar resultados comparables a los reportados en el trabajo original.

Arquitectura del modelo y parámetros explorados

La implementación del modelo se organizó en cuatro módulos principales siguiendo criterios de modularidad:

- LineGraph, encargado de construir el grafo lineal descrito en el artículo original, extendiendo las relaciones para su procesamiento estructural.
- FactFeatureExtractor, responsable de extraer y preprocesar el vocabulario del grafo, aplicar procesos de lematización y almacenar las representaciones utilizadas tanto durante entrenamiento como en la etapa de evaluación.
- AttentiveAggregator, que implementa el mecanismo de atención definido en el modelo, siguiendo la formulación matemática propuesta en el artículo.
- TrainIKGE, módulo encargado de orquestar el proceso de entrenamiento, optimización y evaluación del modelo.

Durante el proceso de implementación se identificaron varios aspectos de la arquitectura que requerían ajustes prácticos para permitir la convergencia del modelo.

Ajustes necesarios para convergencia de model modelo

Puerta Suave (Soft Floor Gate) en el Type Matching

La Ecuación 5 del artículo define un mecanismo de compuerta lógica para el type matching, en el cual la coincidencia de tipos entre entidad y relación se implementa mediante una multiplicación binaria (0 o 1). Si los tipos de la entidad no satisfacen exactamente las restricciones de dominio o rango de la relación, la característica generada se convierte en un vector nulo.

En la práctica, esta formulación presenta limitaciones debido a que las ontologías de DBpedia y Freebase son jerárquicas. Por ejemplo, una entidad tipada como `dbo:President` satisface implícitamente la restricción `dbo:Person`, pero una intersección plana de tensores no captura esta relación jerárquica.

Los diagnósticos iniciales mostraron que aproximadamente 87.4% de los gradientes colapsaban a cero en la primera época de entrenamiento, lo que impedía el aprendizaje efectivo del modelo.

Para mitigar este problema se implementó una puerta suave (soft floor gate) definida como:

$$type_{gate} = 0.1 + 0.9 * type_{validity}$$

En ausencia de coincidencia directa de tipos, el modelo retiene un 10% de la señal estructural generada por la GCN, permitiendo la propagación del gradiente a través de jerarquías ontológicas implícitas. Adicionalmente, se permite una validez de 1.0 en casos donde la entidad no posee tipos registrados.

Función de Pérdida: De BCE a Hinge Ranking Loss

El artículo original propone entrenar el modelo utilizando Binary Cross-Entropy (BCE). Durante los experimentos iniciales se observó que las predicciones tendían a colapsar alrededor de logits cercanos a cero (sigmoide ≈ 0.5), lo que provocaba cancelación entre gradientes positivos y negativos.

Para estabilizar el entrenamiento se adoptó una Hinge Margin Ranking Loss con margen $m = 0.5$:

$$L = \max(0, m - score_{pos} + score_{neg})$$

Esta función de pérdida penaliza únicamente los casos en los que la diferencia entre la puntuación positiva y la negativa no supera el margen definido, incentivando al modelo a aprender una separación clara entre ejemplos positivos y negativos.

Construcción de Subgrafos K -hop BFS

Durante el entrenamiento se construyen subgrafos locales alrededor de cada tripleta objetivo utilizando una exploración Breadth-First Search (BFS) hasta profundidad K . Este subgrafo constituye el vecindario estructural utilizado por el modelo para realizar inferencia.

La tripleta objetivo se inserta dinámicamente como un nodo virtual durante el entrenamiento, evitando así fugas de información (data leakage) y manteniendo consistencia con el procedimiento de inferencia descrito en el artículo.

Los experimentos realizados muestran que un valor de $K = 2$ resulta suficiente para obtener resultados comparables con los reportados en el estudio original tanto en DBpedia50k como en FB20k, mientras que valores mayores tienden a introducir ruido estructural innecesario.

Brechas de reproductividad identificadas

Durante el proceso de implementación se identificaron diversas omisiones en la descripción original del artículo, incluyendo detalles relevantes de ingeniería algorítmica. En total se documentaron 16 brechas de reproducibilidad, de las cuales destacan las siguientes:

Muestreo negativo estructural

El artículo original indica que los ejemplos negativos se generan reemplazando aleatoriamente la entidad cabeza o cola de una tripleta. Sin embargo, no especifica la población candidata para este muestreo.

Una implementación inicial que incluía entidades Out-of-KG provocó que el modelo aprendiera una regla trivial: si una entidad no posee vecinos estructurales, la tripleta es falsa. Esto condujo a resultados artificialmente altos durante el entrenamiento, pero un colapso en la evaluación de ranking completo.

Para resolver este problema se restringió el muestreo negativo a entidades In-KG, además de implementar cubetas de muestreo restringidas por tipo (type-constrained negative sampling), lo que fuerza al modelo a utilizar información semántica adicional para discriminar entre tripletas verdaderas y falsas.

Hiperparámetros No especificados

El artículo original omite la especificación de varios hiperparámetros relevantes. En esta implementación se utilizaron las siguientes configuraciones:

- Batch size: 256

- Entrenamiento: hasta 200 épocas
- Scheduler: Cosine Annealing Learning Rate
- Early stopping: basado en la pérdida del conjunto de validación

Debido a limitaciones computacionales, el entrenamiento final del modelo sobre FB20k se detuvo después de 30 épocas, alcanzando valores de pérdida comparables a los obtenidos en el entrenamiento de DBpedia50k, que convergió aproximadamente en 63 épocas.

Métricas de evaluación

El desempeño de ambos modelos se evaluó utilizando métricas estándar en tareas de predicción de enlaces en grafos de conocimiento. En particular, se utilizaron las métricas Mean Reciprocal Rank (MRR), Hits@10 y Hits@1, que permiten evaluar la capacidad del modelo para posicionar correctamente la entidad objetivo dentro del ranking de predicciones.

La métrica MRR mide el promedio del inverso de la posición en la que aparece la respuesta correcta dentro del ranking generado por el modelo.

$$MRR = \frac{1}{N} \sum_{i=1}^N \frac{1}{rank_i}$$

Donde $rank_i$ corresponde a la posición de la entidad correcta en el ranking generado para la tripleta i y N es el número total de evaluadas. Esta métrica proporciona una medida global del desempeño del sistema al considerar la calidad del ordenamiento completo de las predicciones.

Por su parte, Hits@ k mide la proporción de casos en los que la entidad correcta aparece dentro de las primeras k posiciones del ranking. En este trabajo se reportan Hits@10 y Hits@1, definidos como:

$$Hits@k = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(rank_i \leq k)$$

Donde $\mathbb{I}(\bullet)$ es una función indicadora que toma valor 1 cuando la condición se cumple y 0 en caso contrario.

Estas métricas permiten evaluar tanto la calidad global del ranking generado por el modelo (MRR) como su capacidad para ubicar la entidad correcta entre las primeras posiciones del ranking (Hits@ k).

Infraestructura computacional

Los experimentos se ejecutaron en un entorno de cómputo con soporte para aceleración mediante GPU. Para el modelo InGram se utilizó una GPU RTX 6000 Ada, mientras que la implementación y experimentación del modelo IKGE se ejecutó en GPUs RTX 5060 Ti, RTX 5070 Ti y RTX 3090. La implementación y entrenamiento de los modelos se realizaron utilizando el framework PyTorch, ampliamente utilizado para el desarrollo de modelos de aprendizaje profundo.

La disponibilidad de recursos de cómputo acelerado permitió ejecutar múltiples configuraciones experimentales en tiempos razonables, particularmente durante la exploración de distintos niveles de profundidad estructural y configuraciones del modelo.

Para el proceso de implementación del modelo IKGE se emplearon herramientas de asistencia de programación basadas en modelos de lenguaje, específicamente Claude Sonnet 4.6 a través de GitHub Copilot for Students integrado en Visual Studio Code, operando sobre contenedores remotos con acceso a GPUs mediante conexiones SSH. Estas herramientas se utilizaron como apoyo para la generación asistida de fragmentos de código, documentación de implementación y resolución de problemas relacionados con la ingeniería del sistema, siempre bajo supervisión y validación directa durante el proceso de desarrollo.

Características estructurales de los grafos

Característica	NL-25 (NELL)	WK-25 (WordNet)	FB-25 (Freebase)
Origen	Extracción automática desde texto web	Base léxica curada manualmente	Base enciclopédica estructurada
Tipo de grafo	Semántico abierto	Jerárquico taxonómico	Enciclopédico heterogéneo
Naturaleza de relaciones	Amplias y variadas (locatedIn, worksFor, presidentOf)	Principalmente jerárquicas (hypernym, hyponym)	Mixtas (bornIn, directedBy, industry, currency)
Regularidad estructural	Media-baja	Alta	Media
Profundidad típica de caminos	Corta a media	Larga y jerárquica	Variable
Densidad relacional	Variable (puede ser ruidosa)	Alta regularidad por categoría	Moderada
Nivel de ruido	Medio-alto (extracción automática)	Bajo (curado manualmente)	Bajo-medio
Riesgo de sobre-propagación	Alto si profundidad grande	Moderado	Alto en propagación excesiva
Comportamiento esperado con mayor profundidad	Puede degradarse por mezcla semántica	Puede beneficiarse hasta profundidad intermedia	Tiende a degradarse si se excede profundidad
Implicación para InGram	La propagación profunda puede amplificar ruido semántico debido a la extracción automática; una profundidad moderada suele ser suficiente para capturar señales útiles	La estructura jerárquica favorece la propagación estructural, permitiendo que profundidades intermedias capturen relaciones taxonómicas	La diversidad relacional permite capturar contexto estructural amplio, pero profundidades excesivas pueden mezclar señales heterogéneas
Implicación para IKGE	Puede verse afectado por ruido en vecinos debido a extracción automática; la calidad del subgrafo local es crítica para generar embeddings fiables	La estructura jerárquica y las relaciones consistentes favorecen la generación de embeddings inductivos a partir de vecinos	El subgrafo local suele ser informativo, pero la heterogeneidad de relaciones puede introducir señales mixtas en la generación de embeddings

Resultados




Experimento InGram

A continuación se presentan los resultados obtenidos en los experimentos realizados con el modelo InGram sobre los conjuntos de datos NL-25, WK-25 y FN-25. En todos los casos se mantuvo fija la profundidad de uno de los componentes del modelo en su valor por defecto ($L=2$), mientras que la profundidad del otro componente se varió de forma independiente para analizar su impacto en el desempeño del modelo. De esta manera, los experimentos etiquetados como `depth_ent_k`

NL-25, L _{other} = 2			
Depth	MRR	Hits@10	Hits@1
1	0.159	0.306	0.075
2	0.255	0.371	0.189
3	0.111	0.188	0.069
4	0.043	0.082	0.018
1	0.263	0.409	0.185
2	0.247	0.353	0.189
3	0.220	0.326	0.167
4	0.138	0.271	0.081

WK-25; L _{other} = 2			
Depth	MRR	Hits@10	Hits@1
1	0.105	0.172	0.064
2	0.109	0.210	0.055
3	0.112	0.211	0.060
1	0.117	0.211	0.066
2	0.116	0.200	0.078
3	0.130	0.210	0.087

FN-25;L _{other} = 2			
Depth	MRR	Hits@10	Hits@1
1	0.088	0.176	0.040
2	0.100	0.222	0.041
3	0.101	0.225	0.040
1	0.097	0.222	0.034
2	0.112	0.242	0.048
3	0.084	0.184	0.032



corresponden a configuraciones en las que se varió la profundidad de agregación de entidades, mientras que los experimentos `depth_rel_k` modifican la profundidad de agregación de relaciones. Los resultados se reportan utilizando las métricas MRR, Hits@10 y Hits@1.

Experimento IKGE

Estos fueron los resultados obtenidos en la implementación de IKGE con el dataset de FB20k. El análisis se desglosa en la clasificación en los 4 Grupos de Evaluación dictados por el artículo, probando las 85,557 tripletas del conjunto de prueba en forma vectorizada sobre GPU. Los resultados sintetizan la capacidad del modelo para adivinar el nodo (o relación) faltante, evaluado mediante Mean Reciprocal Rank (MRR) y Mean Rank (MR).

Grupo de Evaluación del Paper	Patrones O/X Evaluados	Nº Tripletas	MRR Obtenido	Mean Rank	Objetivo MRR (FB20k+)	Diagnóstico
Group 1 - Head Pred.	O-O-X, O-X-X, O-X-O	13,105	0.3064	552.8	0.39	Sólido teniendo la posibilidad de hacer mas épocas de entrenamiento
Group 2 - Tail Pred.	X-O-O, X-X-O, O-X-O	20,272	0.3771	165.7	0.4	Sólido; la predicción de cola con texto rinde bien.
Group 3 - Head+Tail OOK	O-O-X (H), X-O-O (T)	26,085	0.4053	49	0.42	Sólido; El muestreo negativo permite al modelo generalizar a entidades OOKG.
Group 4 - Relation Pred.	O-O- X, X-O-O, X-O-X	26,095	0.0396	413.1	0.36	Subóptimo (Colapso por Bug en el entrenamiento).
Nota sobre notación del paper original: (Head-Relation-Tail), donde O = In-KG (Conocido) y X = Out-of-KG (Desconocido).						

Adicional a las tablas del artículo original, diseñamos un experimento de clasificación binaria para determinar con otras métricas las capacidades de generalización del modelo. Tras calibrar el umbral óptimo con el valor de pérdida visto durante el entrenamiento en el subconjunto de validación ($\tau = 0.38$), probamos un set balanceado (1:1 Verdadero/Falso con negativos difíciles) de 88,142 tripletas:

Segmento de Inferencia	Precisión (Acc)	Precision	Recall	F1-Score
in_KG (Todo conocido)	0.8525	0.8128	0.9159	0.8613
out_T (Cola desconocida)	0.7881	0.8028	0.7637	0.7828
out_H (Cabeza desconocida)	0.7694	0.78	0.7506	0.765
out_RT (Cola y Rel desconocidos)	0.6891	0.8327	0.4733	0.6035

Discusión

Comparación entre InGram vs IKGE

A partir de los resultados presentados en la sección anterior, es posible identificar patrones consistentes en el comportamiento de los modelos evaluados, particularmente en relación con la profundidad de propagación estructural

Un enfoque alternativo para abordar el problema de la predicción inductiva en grafos de conocimiento es el propuesto por modelos como Inductive Knowledge Graph Embedding (IKGE), los cuales se apoyan en representaciones semánticas derivadas de texto. En este tipo de modelos, los embeddings de entidades y relaciones se obtienen a partir de la información textual asociada a ellas, como nombres, descripciones o atributos disponibles en recursos externos. Dichas representaciones textuales se transforman mediante modelos de lenguaje o técnicas de embedding semántico para producir vectores que posteriormente son utilizados en tareas de predicción de enlaces.

En contraste, InGram adopta un enfoque fundamentalmente estructural para el problema inductivo. En lugar de depender de descripciones textuales, el modelo construye representaciones a partir de la estructura del grafo de conocimiento. Para ello, primero se define un grafo de relaciones, donde cada nodo corresponde a un tipo de relación y las aristas representan afinidades entre relaciones calculadas a partir de patrones estructurales observados en el grafo. A partir de este grafo se generan representaciones ocultas de las relaciones, las cuales posteriormente se utilizan en el proceso de agregación de información para construir representaciones de entidades.

La representación de cada entidad se obtiene mediante la agregación de información proveniente de su vecindario en el grafo, considerando tanto las entidades conectadas como los tipos de relaciones que las vinculan. De esta manera, el modelo aprende a producir representaciones latentes utilizando únicamente información estructural local. Un aspecto clave del diseño de

InGram es que el modelo no aprende embeddings específicos para entidades o relaciones individuales, sino que aprende los parámetros de una función de agregación capaz de generar representaciones para cualquier entidad o relación a partir de su contexto estructural. Esta característica permite que el modelo pueda generalizar a entidades no observadas durante el entrenamiento, lo cual es fundamental en escenarios inductivos.

Impacto de la estructura del grafo

Efecto de la profundidad L1, L2, L3

InGram

Los resultados obtenidos muestran un comportamiento consistente en el caso de la profundidad asociada a entidades. En los tres conjuntos de datos evaluados, la configuración con profundidad $L_e=2$ —correspondiente a la agregación de información proveniente de vecinos y vecinos de vecinos— se encuentra entre los mejores resultados reportados. En el conjunto NL-25, esta configuración alcanza el mejor desempeño en todas las métricas evaluadas, mostrando una mejora notable respecto a profundidades menores o mayores. En los conjuntos WK-25 y FB-25, aunque la configuración $L_e=2$ no siempre corresponde estrictamente al valor máximo, su desempeño se mantiene muy cercano al mejor resultado observado, lo que sugiere que incorporar información estructural hasta el segundo nivel del vecindario es suficiente para capturar la mayor parte de las dependencias relevantes en el grafo.

Por otro lado, al incrementar la profundidad más allá de este nivel se observa una degradación clara en el desempeño, particularmente visible en NL-25, donde profundidades mayores provocan una disminución significativa en las métricas. Este comportamiento sugiere que una propagación excesiva de información puede introducir ruido estructural o diluir las señales locales más relevantes para la tarea de predicción de enlaces.

En contraste, la profundidad asociada a relaciones presenta un comportamiento menos uniforme entre conjuntos de datos. Mientras que en NL-25 el mejor resultado se obtiene con una profundidad mínima ($L_r=1$), en WK-25 el desempeño mejora gradualmente al aumentar la profundidad hasta $L_r=3$. En FB-25, por su parte, la mejor configuración corresponde a $L_r=2$, mientras que profundidades mayores vuelven a deteriorar el rendimiento. Estos resultados sugieren que la propagación de información entre relaciones depende en mayor medida de las características estructurales particulares de cada grafo de conocimiento.

En conjunto, estos hallazgos indican que la profundidad óptima del modelo no es necesariamente simétrica entre entidades y relaciones. Mientras que la agregación de información en entidades

parece estabilizarse consistentemente en un vecindario de segundo orden, la profundidad óptima para relaciones varía entre conjuntos de datos, lo que sugiere que la profundidad óptima no es universal, depende del régimen estructural del grafo.

IKGE

Los resultados obtenidos en la implementación de IKGE también sugieren que utilizar un nivel de profundidad alto puede degradar el performance completo del modelo. Si bien nuestros resultados no permiten comparar los casos superior e inferior y afirmar con completa certeza si una degradación en la calidad puede suceder, sí sugieren que resultados comparativamente buenos en performance pueden obtenerse si se utiliza un k-hop menor que el utilizado durante el estudio original de 3, lo que ahorra en procesamiento computacional, almacenamiento y complejidad del entrenamiento.

De la misma manera, esta decisión nos lleva a recordar el régimen estructural del grafo que beneficia a un modelo como IKGE. Podemos afirmar de nuestros resultados que un grafo de baja densidad no permite concebir a IKGE como una opción predictiva eficiente, dada la pérdida que el grafo experimentará por el type matching estricto y pocos hechos adyacentes (facts) conectados por entidad.

Selección Adaptativa de profundidad de propagación

Motivación para selección adaptativa

Los resultados experimentales muestran que, a diferencia de la profundidad asociada al módulo de entidades, la profundidad óptima para la agregación de relaciones no presenta un comportamiento consistente entre los distintos conjuntos de datos analizados. Mientras que en algunos casos el mejor desempeño se obtiene con niveles de propagación relativamente bajos, en otros escenarios el modelo se beneficia de una mayor profundidad en el grafo de relaciones.

Este comportamiento sugiere que la utilidad de expandir el vecindario de relaciones depende fuertemente de las características estructurales del grafo de conocimiento, tales como la densidad relacional, los patrones de co-ocurrencia entre relaciones o la distribución de conectividad entre tipos de predicado.

A partir de esta observación surge la posibilidad de desarrollar un mecanismo de selección adaptativa de profundidad, basado en un análisis estructural previo del grafo de relaciones. Dicho análisis permitiría estimar, de forma aproximada, el nivel de profundidad más adecuado para la propagación de información entre relaciones antes del proceso de entrenamiento.

Actualmente, la forma más directa de identificar esta configuración consiste en realizar múltiples ejecuciones del modelo variando el número de capas, lo cual implica un costo computacional considerable. Un procedimiento de análisis estructural preliminar podría reducir significativamente este espacio de búsqueda, proporcionando indicadores que orienten la selección inicial de profundidad en el modelo y disminuyendo el costo experimental necesario para encontrar configuraciones eficientes.

Enfoque para selección adaptativa

La variabilidad observada en el comportamiento de la profundidad óptima para la agregación de relaciones sugiere que este parámetro depende de las características estructurales del grafo de relaciones asociado al conjunto de datos. Bajo esta perspectiva, la selección de profundidad puede formularse como un problema de inferencia basado en propiedades estructurales del grafo.

Sea $G_r = (R, E_r)$ el grafo de relaciones, donde R representa el conjunto de relaciones y E_r las conexiones estructurales entre ellas. El objetivo consiste en determinar una profundidad óptima de propagación para el módulo de relaciones del modelo, denotada como:

$$L_r^* \in \{1, 2, \dots, L_{max}\}$$

Donde L_{max} corresponde al máximo número de capas consideradas en el proceso de agregación estructural.

La selección adaptativa de profundidad puede plantearse como una función de las propiedades estructurales del grafo de relaciones:

$$L_r^* = g(S(G_r))$$

Con $S(G_r)$ un vector de propiedades estructurales, como densidad, grado promedio, diámetro o coeficiente de clustering.

Donde $g(\bullet)$ puede implementarse mediante reglas heurísticas, funciones de optimización o modelos predictivos. Bajo esta formulación, la elección de profundidad deja de tratarse como una búsqueda exhaustiva y se convierte en un problema de inferencia guiada por la estructura del grafo.

Algunas de estas propiedades pueden definirse formalmente de la siguiente manera. La densidad del grafo de relaciones puede expresarse como:

$$\delta(G_r) = \frac{2|E_r|}{|R|(|R| - 1)}$$

mientras que el grado promedio del grafo se define como:

$$\bar{k}(G_r) = \frac{1}{|R|} \sum_{r \in R} \deg(r)$$

Otra propiedad relevante es el diámetro del grafo, que corresponde a la mayor distancia geodésica entre pares de nodos:

$$D(G_r) = \max_{u,v \in R} d(u, v)$$

Estas métricas permiten caracterizar el nivel de conectividad y la extensión de la propagación de información dentro del grafo de relaciones.

Bajo esta formulación, la profundidad óptima puede estimarse mediante reglas heurísticas o funciones de decisión basadas en dichas propiedades estructurales. Por ejemplo, grafos con alta densidad relacional podrían requerir niveles de propagación más bajos, mientras que grafos más dispersos podrían beneficiarse de profundidades mayores que permitan capturar dependencias estructurales más lejanas.

Alternativamente, la profundidad puede seleccionarse en función del alcance estructural logrado tras múltiples pasos de propagación. Sea $N^L(r)$ el conjunto de relaciones alcanzables desde una relación r tras L pasos en el grafo de relaciones. Definimos entonces la cobertura promedio del grafo como:

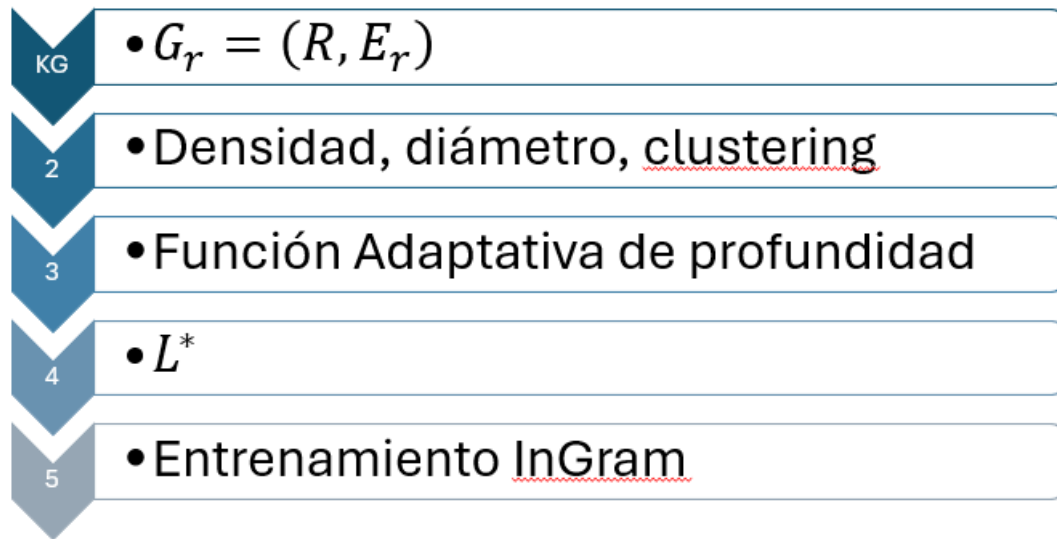
$$\Gamma(L) = \frac{1}{|R|} \sum_{r \in R} \frac{|N^L(r)|}{|R|}$$

La profundidad puede seleccionarse como el menor valor de L que alcance un nivel deseado de cobertura estructural:

$$L_r^* = \min \{L : \Gamma(L) \geq \eta\}$$

Donde η representa un umbral de cobertura estructural predefinido.

Bajo este enfoque, la selección de profundidad deja de depender exclusivamente de exploración experimental y puede abordarse mediante análisis estructural previo del grafo de relaciones, reduciendo el espacio de búsqueda de hiperparámetros y el costo computacional asociado al entrenamiento del modelo.



Conclusión

En este trabajo se analizó el comportamiento de modelos inductivos de Knowledge Graph Embedding en escenarios de extrapolación donde aparecen entidades no observadas durante el entrenamiento. En particular, se evaluó el efecto de la profundidad de propagación estructural en el modelo InGram, así como su relación con el desempeño obtenido en tareas de predicción de enlaces.

Uno de los supuestos comunes en modelos basados en propagación estructural es que incrementar el número de capas o niveles de agregación conduce a representaciones más informativas. Sin embargo, los resultados obtenidos en los experimentos muestran que este supuesto no se cumple necesariamente en todos los casos. Tanto en InGram como en IKGE se observa de manera consistente que una profundidad de nivel 2 en el módulo de entidades produce el mejor desempeño, lo que sugiere que existe un punto óptimo de agregación para capturar información contextual relevante sin introducir ruido adicional proveniente de vecindarios estructurales más lejanos.

Por otra parte, el análisis del módulo de relaciones en InGram revela un comportamiento distinto. A diferencia de la propagación sobre entidades, la profundidad óptima para la agregación de relaciones no presenta un patrón uniforme entre los distintos conjuntos de datos analizados. Mientras que en algunos casos profundidades bajas producen mejores resultados, en otros escenarios el modelo se beneficia de niveles de propagación mayores. Este resultado sugiere que la profundidad asociada al grafo de relaciones no constituye un parámetro absoluto, sino que depende de las características estructurales particulares de cada conjunto de datos.

A partir de este hallazgo, se plantea la necesidad de desarrollar mecanismos que permitan estimar de forma adaptativa la profundidad adecuada para la propagación de información en el grafo de relaciones. En lugar de determinar este parámetro exclusivamente mediante exploración experimental, sería posible utilizar propiedades estructurales del grafo de relaciones como indicadores para orientar la selección inicial de profundidad en el modelo.

En conjunto, los resultados obtenidos muestran que, mientras que una profundidad moderada resulta suficiente para capturar información contextual a nivel de entidades, la propagación sobre relaciones presenta una mayor sensibilidad a la estructura del grafo. Esto abre una línea de investigación orientada a la selección adaptativa de profundidad basada en análisis estructural del grafo, con el objetivo de mejorar la eficiencia del proceso de entrenamiento y facilitar la configuración de modelos inductivos en grafos de conocimiento.

En particular, la estabilidad observada en la profundidad óptima de entidades sugiere la existencia de un límite estructural en la cantidad de contexto útil que puede agregarse en grafos de conocimiento sin introducir ruido estructural.

Trabajo futuro

Los resultados obtenidos en este trabajo sugieren varias líneas de investigación orientadas a profundizar en la comprensión del comportamiento de modelos inductivos de Knowledge Graph Embedding en escenarios de extrapolación.

Una primera dirección consiste en estudiar de manera sistemática la relación entre las propiedades estructurales del grafo de relaciones y la profundidad óptima de propagación en modelos como InGram. Los resultados experimentales muestran que, mientras la profundidad asociada a las entidades presenta un comportamiento relativamente estable, la profundidad en el módulo de relaciones depende significativamente de las características del conjunto de datos. Esto sugiere que propiedades estructurales del grafo —como la densidad relacional, la distribución de grados entre predicados, o los patrones de co-ocurrencia entre tipos de relación— podrían influir directamente en la cantidad de información útil que puede propagarse a través de la estructura del grafo.

En este contexto, una línea prometedora de investigación consiste en desarrollar métodos para estimar de manera automática la profundidad de propagación a partir de características estructurales del grafo. En lugar de determinar este hiperparámetro mediante exploración experimental, sería posible diseñar mecanismos de selección adaptativa que utilicen métricas topológicas o representaciones estructurales del grafo de relaciones para orientar la configuración inicial del modelo. Este enfoque podría reducir significativamente el costo computacional asociado a la búsqueda de hiperparámetros y facilitar la aplicación de modelos inductivos en grafos de conocimiento de mayor escala.

Otra dirección relevante consiste en extender el análisis experimental a diferentes tipos de configuraciones inductivas, incluyendo escenarios donde aparecen simultáneamente nuevas entidades y nuevas relaciones. Este tipo de escenarios representa una situación más cercana a aplicaciones reales, donde los grafos de conocimiento evolucionan continuamente y la aparición de nuevas entidades suele estar acompañada por la introducción de nuevas relaciones o patrones semánticos.

Finalmente, futuras investigaciones podrían explorar arquitecturas que aprendan dinámicamente la profundidad de propagación durante el proceso de entrenamiento, permitiendo que el modelo ajuste automáticamente el alcance de la agregación estructural en función de la información disponible en el grafo. Este tipo de aproximación podría contribuir al desarrollo de modelos más robustos y adaptativos para tareas de extrapolación en grafos de conocimiento.

Referencias

- Bordes, A., Usunier, N., Garcia-Durán, A., Weston, J., & Yakhnenko, O. (2013). Translating embeddings for modeling multi-relational data. In *Advances in Neural Information Processing Systems* (Vol. 26).
<https://papers.nips.cc/paper/2013/hash/1cecc7a77928ca8133fa24680a88d2f9-Abstract.html>
- Chen, M., Zhang, W., Geng, Y., Xu, Z., Pan, J. Z., & Chen, H. (2023). Generalizing to unseen elements: A survey on knowledge extrapolation for knowledge graphs. *arXiv preprint arXiv:2302.01859*.
<https://arxiv.org/abs/2302.01859>
- Hamilton, W. L., Ying, R., & Leskovec, J. (2017). Inductive representation learning on large graphs. In *Advances in Neural Information Processing Systems* (Vol. 30).
<https://arxiv.org/abs/1706.02216>
- Hamaguchi, T., Oiwa, H., Shimbo, M., & Matsumoto, Y. (2017). Knowledge transfer for out-of-knowledge-base entities: A graph neural network approach. *arXiv preprint arXiv:1706.05674*.
<https://arxiv.org/abs/1706.05674>
- Lee, J., Chung, C., & Whang, J. J. (2023). INGRAM: Inductive knowledge graph embedding via relation graphs. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(03), 4054–4061.
<https://doi.org/10.1609/aaai.v34i03.5865>
- Nickel, M., Murphy, K., Tresp, V., & Gabrilovich, E. (2016). A review of relational machine learning for knowledge graphs. *Proceedings of the IEEE*, 104(1), 11–33.
<https://doi.org/10.1109/JPROC.2015.2483592>
- Oh, B., Seo, S., Hwang, J., Lee, D., Lee, K. (2022). Open-world knowledge graph completion for unseen entities and relations via attentive feature aggregation. In *Information Sciences*, 586, 468–484.
- Pennington, J., Socher, R., & Manning, C. (2014). GloVe: Global vectors for word representation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1532–1543.

- Schlichtkrull, M., Kipf, T. N., Bloem, P., van den Berg, R., Titov, I., & Welling, M. (2018). Modeling relational data with graph convolutional networks. In *The Semantic Web – ESWC 2018* (Lecture Notes in Computer Science, Vol. 10843, pp. 593–607). Springer. https://doi.org/10.1007/978-3-319-93417-4_38
- Teru, K. K., Denis, E., & Hamilton, W. L. (2020). Inductive relation prediction by subgraph reasoning. In *Proceedings of the 37th International Conference on Machine Learning* (pp. 9448–9457). PMLR. <https://arxiv.org/abs/1911.06962>
- Wang, Q., Mao, Z., Wang, B., & Guo, L. (2017). Knowledge graph embedding: A survey of approaches and applications. *IEEE Transactions on Knowledge and Data Engineering*, 29(12), 2724–2743. <https://doi.org/10.1109/TKDE.2017.2754499>
- Yamada, I., Asai, A., Sakuma, J., Shindo, H., Takeda, H., Takefuji, Y., & Matsumoto, Y. (2020). Wikipedia2Vec: An efficient toolkit for learning and visualizing the embeddings of words and entities from Wikipedia. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 23–30.